Analyse multicentrique des hyperintensités de la substance blanche : prétraitement, contrôle qualité, segmentation, biomarqueurs et harmonisation

Jean Barreto

Octobre 2026

Résumé

1 Introduction

1.1 Contexte clinique

Les hyperintensités de la substance blanche (HSB) sont des zones anormalement claires de la substance blanche cérébrale sur les séquences IRM pondérées en T2, en particulier la séquence FLAIR qui atténue le signal du liquide céphalorachidien et fait ressortir les lésions. Elles sont l'un des principaux marqueurs d'imagerie de la maladie des petits vaisseaux cérébraux, dont les critères de description ont été standardisés par le consortium STRIVE [1]. Très fréquentes avec l'âge, elles sont associées à un risque accru d'accident vasculaire cérébral, de déclin cognitif et de démence [2].

En pratique clinique, leur sévérité est souvent évaluée par des échelles visuelles comme celle de Fazekas [3], qui distingue les lésions périventriculaires et profondes. En recherche, on préfère une mesure quantitative tel que le volume de HSB, ou charge lésionnelle, éventuellement rapporté au volume intracrânien. Ce biomarqueur, comme d'autre, suppose une segmentation des lésions HSB. La segmentation à la main est un processus long et variable d'un expert à l'autre ce qui la rend inadapté à de grands volumes de données. C'est ici que l'intérêt des méthodes automatiques arrive, et en particulier de l'apprentissage profond. [4].

1.2 Le problème multicentrique

Pour pouvoir relier ces biomarqueurs au pronostic des patients on utilise des cohortes de données dont les images proviennent de différents scanners, centres, protocoles, résolution, etc. Cette hétérogénéité pose trois problèmes.

Le premier relève de la qualité des images, sur un ensemble aussi grand la probabilité d'avoir des images inutilisable augmente. Cela peut être du à des artefacts de mouvement, un bruit excessif ou un champ de biais anormal qui fausserait la segmentation silencieusement. Un contrôle qualité est donc indispensable dans la conception du traitement d'un tel volume de données. Il existent des outils de référence tel que MRIQC [5], mais ce dernier n'est pas conçus pour des images en FLAIR.

Le deuxième est la perte de généralisation d'un réseau de neurones sur des scanners qu'il n'a pas vu à l'entraînement. Le Challenge MICCAI WMH 2017 [6], dont on utilise les données, a été conçu pour tester cette situation : deux des cinq scanners sont absents du split d'entraînement.

Le troisième soucis est le manque de comparabilité entre mesures. Une IRM n'a pas d'unité d'intensité standardisé et un même tissu peut avoir des valeurs d'intensité très différents d'un scanner à l'autre. Les images contiennent alors une signature des scanners d'acquisition ce qui peut

se confondre avec un effet de la maladie dans une analyse de groupe. Les méthodes d'harmonisation tel que la normalisation d'intensité ou ComBat [7, 8] visent à retirer cette signature sans effacer le signal biologique.

1.3 Questions et contributions

Ce travail implémente une chaîne de traitement reproductible, des images brutes aux biomarqueurs, sur les 170 IRM (FLAIR et T1) des cinq scanners du challenge MICCAI WMH 2017. Il s'efforce de répondre à quatre questions :

1. **Repérer les images problématiques** : un contrôle qualité inspiré de MRIQC et adapté à la FLAIR détecte-t-il les images dégradées avant qu'elles n'impacte la qualité de segmentation ?
2. **Segmenter les lésions de façon fiable, y compris sur un scanner jamais vu** : comment se comparent un modèle entraîné sur ces données (nnU-Net), un modèle publié prêt à l'emploi (WMH-SynthSeg) et une méthode classique (seuillage), et à quelle distance du niveau humain ?
3. **Obtenir des biomarqueurs comparables d'un site à l'autre** : le volume de lésions mesuré automatiquement est-il aussi juste qu'un second expert, et son erreur dépend-elle du scanner ?
4. **Retirer l'empreinte du scanner sans effacer la biologie** : la normalisation d'intensité et ComBat suffisent-ils à rendre les mesures comparables entre sites ?

Les contributions sont les suivantes. (i) Une chaîne complète et documentée, du téléchargement des données à l'analyse statistique, avec un workflow Snakemake, un environnement verrouillé, des tests automatisés et des conteneurs. (ii) Un contrôle qualité adapté à la FLAIR, validé sur des artefacts simulés et sur leur effet réel sur la segmentation. (iii) Une évaluation rigoureuse des trois méthodes de segmentation, avec le script officiel du challenge, des intervalles de confiance par bootstrap, des comparaisons appariées corrigées pour les tests multiples et un plafond inter-observateurs. (iv) Une analyse de l'accord des biomarqueurs avec la référence, globalement et par site. (v) Une étude de l'harmonisation inter-sites, qui mesure l'empreinte du scanner par un classifieur de site et vérifie la conservation du signal biologique après ComBat.

2 Données

2.1 Le challenge MICCAI WMH 2017

Les données proviennent du challenge de segmentation des HSB organisé lors de la conférence MICCAI 2017 [6]. L'ensemble des données d'entraînement et de test sont herbergées sur la plateforme DataverseNL sous licence CC BY-NC 4.0. Les images sont téléchargées par l'API de DataverseNL pour un ensemble de 1 551 fichiers et 4,1 Go, dont l'intégrité est vérifiée par leur empreinte SHA-1.

Le jeu comprend 170 patients, chacun avec une FLAIR et une T1 3D. Ils proviennent de trois centres et de cinq scanners de trois constructeurs à 1,5 et 3 Teslas (tableau 1). Les organisateurs ont réparti les patients en 60 cas d'entraînement et 110 cas de test, et ont volontairement exclu deux scanners de l'entraînement. Ce découpage permet de mesurer la performance d'un modèle sur des scanners qu'il n'a jamais vus, c'est-à-dire sa capacité de généralisation hors domaine.

TABLE 1 – Les cinq scanners du challenge : effectifs, résolution d'acquisition et résolution des images fournies par les organisateurs (taille des voxels en mm). Les FLAIR fournies sont toutes reconstruites en coupes axiales de 3 mm. Les T1 sont fournies à leur résolution d'acquisition.

Centre et scanner	Champ	Entr.	Test	FLAIR acquise	FLAIR fournie	T1 acquise	T1 fournie
Utrecht, Philips Achieva	3 T	20	30	2D, $0{,}96 \times 0{,}95 \times 3$	$0{,}96 \times 0{,}96 \times 3$	3D, $1 \times 1 \times 1$	$1 \times 1 \times 1$
Singapour, Siemens TrioTim	3 T	20	30	2D, $1 \times 1 \times 3$	$1 \times 1 \times 3$	3D, $1 \times 1 \times 1$	$1 \times 1 \times 1$
Amsterdam, GE Signa HDxt	3 T	20	30	3D, $0{,}98 \times 0{,}98 \times 1{,}2$	$1{,}20 \times 0{,}98 \times 3$	3D, $0{,}94 \times 0{,}94 \times 1$	$0{,}94 \times 0{,}94 \times 1$
Amsterdam, Philips Ingenuity	3 T	0	10	3D, $1{,}04 \times 1{,}04 \times 0{,}56$	$0{,}56 \times 1{,}04 \times 3$	3D, $0{,}87 \times 0{,}87 \times 1$	$0{,}87 \times 0{,}87 \times 1$
Amsterdam, GE Signa HDxt	1,5 T	0	10	3D, $1{,}21 \times 1{,}21 \times 1{,}3$	$1{,}30 \times 1{,}21 \times 3$	3D, $0{,}98 \times 0{,}98 \times 1{,}5$	$0{,}98 \times 0{,}98 \times 1{,}5$
Total		60	110				

Les FLAIR d'Utrecht et de Singapour sont acquises en 2D avec des coupes axiales de 3 mm, alors que celles d'Amsterdam sont acquises en 3D. Les organisateurs fournissent toutes les FLAIR reconstruites en coupes axiales de 3 mm, sur des grilles de $128 \times 256 \times 103$ à $321 \times 240 \times 83$ voxels selon le scanner, soit des voxels de 1,75 à 4,72 mm^3.

Toutes les images T1 ont été défacées (les voxels du visage sont mis à zéro pour l'anonymisation) et un masque de défacement est fournit afin de pouvoir ignorer ces voxels à certaines étapes de calcul. Les FLAIR provenant du VU Amsterdam sont également défacés, probablement car leurs prise en 3D permet une résolution assez fine pour reconstruire le visage contrairement aux FLAIR de l'UMC Utrecht et du NUHS Singapour.

Pour chaque patient le jeu contient également une version des images prétraitée par les organisateurs. La T1 recalée sur la FLAIR avec elastix [9] et une correction du champ de biais avec SPM12 [10]. Ce prétraitement n'est pas utilisé par la chaîne principale, qui repart des images brutes (section 3) mais sert de point de comparaison pour évaluer notre prétraitement.

Les annotations sont faites sur la grille FLAIR, et toute l'évaluation s'y déroule.

2.2 Annotations et référence

Les HSB de chaque patient ont été délimitées manuellement sur la FLAIR, selon les critères STRIVE [1]. La référence du challenge, notée O1, est le résultat d'un premier expert délimitant les lésions des 170 patients puis d'un second expert (O2) relisant l'ensemble de ces délimitations, signalant les erreurs pour que O1 les corriges.

Chaque annotation comprend trois étiquettes : 0 pour le fond, 1 pour les HSB, et 2 pour les « autres pathologies » comme des infarctus ou d'autres lésions qui ne relèvent pas des HSB. Les voxels de l'étiquette 2 sont ignorés lors de l'évaluation officielle, donc une méthode n'est ni pénalisée ni récompensée sur la segmentation de ces zones. Ce travail applique la même règle partout, y compris au calcul des biomarqueurs.

Deux autres experts, notés O3 et O4, ont délimité indépendamment les 60 cas d'entraînement. Ces annotations multiples permettent de mesurer l'accord entre experts, c'est-à-dire le niveau atteignable par un observateur humain (section 6.6). Elles n'existent que sur l'entraînement, sur le test seule la référence O1 est disponible.

3 Prétraitement

Les organisateurs fournissent des images déjà prétraitées (section 2). Ce travail refait le prétraitement à partir des images brutes afin de maîtriser chaque étape et pouvoir l'appliquer à d'autres jeux de données. La chaîne suit l'ordre suivant :

1. extraction du masque du cerveau sur la T1 brute (HD-BET)
2. recalage rigide de la T1 brute sur la FLAIR brute (ANTs)
3. transport du masque du cerveau sur la grille de la FLAIR, par la transformation du recalage
4. correction du champ de biais de la FLAIR et de la T1 (N4), estimée dans leur masque du cerveau, puis rééchantillonnage de la T1 corrigée sur la grille de la FLAIR.

Le recalage précède la correction de biais parce que N4 a besoin du masque du cerveau sur la grille de la FLAIR, et que ce masque y est transporté par la transformation du recalage. Ce choix rend aussi la transformation indépendante de la correction de biais.

3.1 Conversion BIDS

Les données téléchargées sont réorganisées selon la norme BIDS 1.10 (*Brain Imaging Data Structure*) [11] qui fixe le nom et l'emplacement de chaque fichier et les métadonnées associées. Les images brutes (FLAIR et T1) forment le jeu principal ; les annotations manuelles (O1, O3, O4) et le prétraitement des organisateurs sont rangés comme des dérivés. Chaque patient conserve son identifiant du challenge (`sub-000` à `sub-169`). Un inventaire vérifie la géométrie de chaque image, la validité des étiquettes et la cohérence des grilles entre une image et son annotation. Toutes les sorties du projet sont elles aussi écrites comme des dérivés BIDS.

3.2 Recalage rigide T1 vers FLAIR

La T1 et la FLAIR d'un même patient sont acquises au cours de la même séance et la position de la tête a pu changer entre les deux séquence. Un recalage rigide (trois rotations et trois translations) suffit à les aligner. Il est réalisé avec ANTs [12], la FLAIR y sert d'image fixe et n'est jamais rééchantillonnée puisque les annotations et l'évaluation sont sur sa grille. Les deux séquences ayant des contrastes différents le critère de similarité utilisé est l'information mutuelle, qui mesure la dépendance statistique entre les intensités plutôt que leur égalité. Ce critère est peu sensible au champ de biais ce qui permet de recaler sur les images brutes. Le calcul est rendu déterministe (graine fixée, un seul fil d'exécution) ainsi deux exécutions donnent exactement la même transformation.

Le recalage est contrôlé contre celui des organisateurs (elastix) en utilisant la corrélation entre la T1 brute alignée par chacune des deux transformations ainsi que l'écart géométrique entre les deux transformations. Pour cela les 2 transformations sont appliqués à 5 000 points de la tête depuis la FLAIR (tableau 2) ce qui permet de calculer un écart moyen et maximal. Comparer directement les paramètres de la transforations serait trompeur car les deux outils n'utilisent pas le même centre de rotation.

Table 2 – Recalage rigide ANTs contre elastix sur 169 patients : corrélation des T1 alignées, écart moyen et maximal sur 5 000 points de la tête, rotation relative ; puis médiane et pire valeur sur les patients

	Corrélation	Écart moyen (mm)	Écart maximal (mm)	Rotation (ř)
Médiane, tous scanners	0,998	0,14	0,29	0,11
Pire cas	0,974	0,69	1,36	0,75
Utrecht, Philips 3T	0,999	0,11	0,18	0,06
Singapour, Siemens 3T	0,998	0,13	0,28	0,12
Amsterdam, GE 3T	0,994	0,21	0,45	0,17
Amsterdam, Philips 3T	0,994	0,22	0,51	0,20
Amsterdam, GE 1,5T	0,988	0,46	0,84	0,35

Les deux recalages sont équivalents à une fraction de voxel près. Un seul patient sur 170 dépasse les seuils d'alerte (corrélation inférieure à 0,95, écart supérieur à 2 mm ou rotation supérieure à 2ř) : sub-146, dont la FLAIR qui très bruitée et de contraste atypique rend l'information mutuelle peu discriminante (corrélation de 0,905, écart de 2 mm). Pour ce seul patient on utilisera la transformation elastix fournit par les organisateurs.

3.3 Masque du cerveau et correction de biais

Le masque du cerveau est calculé par HD-BET [13], un réseau de neurones d'extraction du cerveau à partir de la T1 brute dont la résolution de 1 mm donne l'anatomie la plus fine. Il est ensuite transporté sur la grille de la FLAIR par la transformation rigide avec une interpolation adaptée aux étiquettes.

Les 170 masques sont obtenus sans échec ; leur volume médian est de 1 357 ml (de 1 020 à 1 810 ml) et aucun ne sort de l'intervalle de contrôle fixé (900 à 2 000 ml). Ce masque servira tout le long de ce travail : correction de biais, contrôle qualité, seuillage et biomarqueurs.

Les inhomogénéités du champ magnétique et des antennes produisent une variation lente de l'intensité dans l'image ayant pour conséquence qu'un même tissu paraît plus clair d'un côté du cerveau que de l'autre. La méthode N4 [14] estime ce champ comme une surface lisse et multiplicative puis divise l'image par ce dernier. Elle est appliquée à la FLAIR et à la T1 brutes à leur résolution d'origine en estimant le champ dans le masque du cerveau. La T1 corrigée est ensuite rééchantillonnée sur la grille de la FLAIR, pour former avec elle les deux canaux d'entrée de nnU-Net.

La correction est comparée à celle des organisateurs (SPM12) sur les 60 cas d'entraînement. Les champs estimés par les deux méthodes se ressemblent (corrélation de 0,74 à 0,98 selon la modalité et le scanner) et N4 donne des images plus homogènes : la variation de luminosité d'un même tissu mesurée le long de chacune des trois directions de l'espace est plus faible avec N4 qu'avec SPM12 pour 53 à 60 patients en FLAIR comme en T1. La méthode et les résultats détaillés sont donnés en annexe A.

Le choix du prétraitement n'a pas d'effet mesurable sur la segmentation, le même modèle nnU-Net entrainé sur notre chaîne appliqué aux images prétraitées par les organisateurs obtient le même Dice que sur les images prétraitées par notre chaîne (0,803 contre 0,802, section 6). La segmentation est donc peu sensible aux différences entre les deux prétraitements, sans que l'expérience permette de dire lequel serait le meilleur pour entraîner un modèle. L'intérêt de cette chaîne est donc plutôt la maîtrise et la traçabilité depuis les données brutes plutôt qu'un gain de performance.

3.4 Recalage vers l'espace MNI

Pour construire des cartes de groupe (section 7) chaque patient est recalé sur le cerveau commun du modèle MNI152NLin2009cAsym [15]. Les formes des cerveaux diffèrent d'un patient à l'autre et en particulier la taille des ventricules (nos sujets ont souvent des ventricules atrophiées), on applique donc un recalage non linéaire : SyN [12] après un recalage rigide puis affine de la T1 du patient vers le modèle.

On remplace l'information mutuelle par la corrélation croisée locale en tant que critère de similarité. Elle est plus coûteuse en calcul mais permet de ramener les ventricules très dilatés des patients atrophiés sur les contours du modèle. Le recalage est fait sur le modèle à 2 mm plutôt qu'à 1 mm car une carte de fréquence n'a pas besoin d'une résolution plus fine que les coupes de 3 mm des FLAIR et cela divise le temps de calcul par huit pour une qualité presque identique. Les masques de lésions sont ensuite transportés de la FLAIR vers la T1 (inverse de la transformation rigide) puis vers le modèle (transformation non linéaire) avec une interpolation linéaire qui conserve la fraction de chaque voxel couverte par une lésion.

4 Contrôle qualité

Sur un grand nombre d'images certaines peuvent être dégradées par le mouvement du patient, un bruit excessif ou un champ de biais anormal et fausser la segmentation de manière silencieuse. Le contrôle qualité mesure des indicateurs de qualité statistique sur chaque image et signale celles qui sont atypiques pour leur scanner puis vérifie deux choses : les images signalées sont-elles moins bien segmentées et le contrôle détecte-t-il des dégradations connues simulées volontairement ?

4.1 Indicateurs de qualité

Les indicateurs reprennent les définitions et les calculs de MRIQC [5], l'outil de référence pour la T1, et sont appliqués aux deux modalités. Huit indicateurs sont retenus : deux rapports signal sur bruit de la substance blanche (l'un avec le bruit mesuré dans le tissu, l'autre avec le bruit mesuré dans l'air), le contraste entre substance blanche et substance grise rapporté au bruit (CNR), le coefficient de variation conjoint des deux tissus (CJV), l'entropie de l'image (EFC, sensible au flou et aux images fantômes), le rapport d'énergie entre la tête et l'air (FBER), l'étendue du champ de biais et la largeur à mi-hauteur du lissage de l'image (FWHM, qui augmente avec le flou de mouvement). Leurs formules sont données en annexe B.

Comme dans MRIQC le bruit et le contraste sont mesurés sur l'image corrigée par N4, le lissage est mesuré sur l'image brute et l'étendue du champ de biais sur la carte de champ. MRIQC n'étant pas conçu pour la FLAIR trois choix s'en écartent volontairement :

— les tissus sont pris dans la segmentation de WMH-SynthSeg plutôt que dans la classification par intensité de MRIQC et les hyperintensités en sont retirées avec une marge de 2 mm, sans quoi le rapport signal sur bruit dépendait de la charge lésionnelle
— l'air est tout l'extérieur de la tête, et non la région située au-dessus de la tête, que nos FLAIR, hautes d'environ 144 mm ne couvrent pas
— le classifieur de MRIQC qui décide si une image est acceptable n'est pas utilisé car il a été entraîné sur des T1 uniquement.

Le CJV n'est par ailleurs jugé que sur la T1 car en FLAIR la substance blanche et la substance grise ont presque la même intensité et ce rapport y prendrait des valeurs extrêmes sans lien avec la qualité.

4.2 Détection des images atypiques

Les indicateurs dépendent fortement du scanner et donc chaque image est donc jugée par rapport aux images de son scanner par un z-score robuste calculé avec la médiane et l'écart absolu médian plutôt qu'avec la moyenne et l'écart type, qu'une image très dégradée tirerait vers elle au point de se masquer elle-même. Le signe est choisi pour qu'un z-score positif signifie toujours « moins bonne qualité ».

Le plus grand z-score d'une image toutes modalités et tous indicateurs confondus classe cette image en *à vérifier* à partir de 3 et *à exclure* à partir de 5. Une forêt d'isolement (*Isolation Forest*) [16] appliquée à l'ensemble des z-scores, ramenés à zéro du côté favorable, signale en plus comme *à vérifier* les images dont la combinaison d'indicateurs est inhabituelle même si aucun n'est extrême à lui seul. Ces classes sont une recommandation de contrôle visuel jamais une exclusion automatique.

Sur les 170 patients 142 images sont utilisables, 20 à vérifier et 8 à exclure. Les signalements viennent surtout de la FLAIR (20 sur 28) et l'indicateur le plus souvent en cause est l'étendue du champ de biais. La forêt d'isolement ne signale aucun patient que les seuils n'aient déjà retenu. La répartition par scanner est donnée en annexe B.

4.3 Lien avec la qualité de segmentation

Si le contrôle qualité est utile les images signalées devraient être moins bien segmentées. Ce lien est mesuré sur les 110 patients de test seulement, le modèle nnU-Net (M1) ayant appris sur ceux de l'entraînement. Les 22 images de test signalées ont un Dice médian de 0,820, contre 0,825 pour les 88 utilisables et le test de Mann-Whitney ne montre pas de différence ($p = 0{,}81$). Le score d'anomalie de la forêt d'isolement n'est que faiblement corrélé au Dice (corrélation de Spearman de 0,17, $p = 0{,}076$).

Les images signalées ne sont donc pas pénalisées à la segmentation. Trois raisons l'expliquent premièrement les organisateurs du challenge ont présélectionné des images de bonne qualité, ensuite

une image atypique pour son scanner n'est pas forcément une image dégradée, et enfin l'indicateur le plus souvent en cause le champ de biais est justement corrigé par N4 avant la segmentation.

4.4 Validation par artefacts simulés

Les images du challenge ayant été présélectionnées par les organisateurs presque toutes sont propres donc on ne peut donc pas vérifier sur elles que le contrôle qualité repère une image réellement dégradée. On fabrique pour cela des images dégradées en ajoutant à des images propres quatre artefacts produits avec TorchIO [17] (bruit, mouvement, champ de biais et images fantômes) chacun à quatre niveaux d'intensité croissante. Au total on réalise des images dégradés sur un total de 30 patients, classés utilisables (6 par scanner) et pris dans le test pour que le modèle M1 ne les ait jamais vus.

On mesure ensuite le taux de détection de notre contrôle qualité sur ces images au sein des images réelles de test. Une image est considérée comme détectée si elle n'est pas classée utilisable.

Ensuite on mesure la segmentation de M1 (nnu-Net) sur ces même images dégradés, en ayant au préalable corrigé le champ avec N4 afin que l'artefact de champ de biais corresponde à un biais résiduel que N4 n'aurait pas retiré.

On sait donc pour chaque image dégradée si elle a été détectée par le contrôle qualité et de combien son Dice a baissé par rapport au même patient sans artefact. On repère directement le cas à risque qui serait une segmentation dégradée (perte de Dice supérieure à 0,05) sur une image que le contrôle qualité n'a pas signalée (tableau 3). Le protocole détaillé et les résultats par niveau sont donnés en annexe B.

Table 3 – Lecture appariée des deux expériences : parmi les 120 FLAIR dégradées par chaque artefact (30 patients, 4 niveaux)

, nombre de segmentations dégradées (perte de Dice supérieure à 0,05) et part de celles que le contrôle qualité a signalées.

Artefact	Segmentations dégradées	Détectées	Non détectées
Bruit	35	31	4
Champ de biais	48	47	1
Images fantômes	40	16	24
Mouvement	99	23	76
Total	222	117	105

Le contrôle signale presque toutes les FLAIR bruitées ou biaisées dont la segmentation se dégrade (4 et 1 manquées sur 35 et 48). Pour le champ de biais 97 % des FLAIR sont signalées dès le niveau 2 alors que le Dice ne décroche qu'au niveau 3 (0,71 contre 0,79 sans artefact).

Les images fantômes ne dégradent la segmentation qu'aux niveaux 3 et 4 (Dice de 0,74 puis 0,66), mais ne sont détectées en FLAIR qu'au niveau 4 et pour 53 % des images seulement : 24 des 40 segmentations dégradées passent inaperçues.

Le mouvement est l'artefact le plus nuisible et le moins bien détecté. Il dégrade la segmentation dès le niveau le plus faible (Dice de 0,74, rappel lésionnel de 0,74 à 0,58) mais seules 23 à 33 % de ces FLAIR sont signalées et 76 des 99 segmentations dégradées passent inaperçues. Le mouvement reste donc la principale limite de ce contrôle qualité.

5 Segmentation

On compare ici trois méthodes de segmentation des HSB : un réseau de neurones entraîné sur ces données (nnU-Net, M1), un réseau publié utilisé tel quel (WMH-SynthSeg, M2) et une règle d'intensité classique (M3). Toutes ces méthodes produisent un masque binaire des lésions sur la grille de la FLAIR et aucun ne voit les 110 cas de test avant l'évaluation (section 6).

TABLE 4 – Les trois méthodes de segmentation comparées.

	Principe	Entrées	Apprentissage
M1 nnU-Net	réseau spécialisé et entraîné sur ces données	FLAIR et T1 corrigées par N4	48 cas d'entraînement, 12 de validation
M2 WMH-SynthSeg	réseau généraliste publié	FLAIR brute	aucun
M3 seuillage	règle d'intensité	FLAIR corrigée par N4, masque du cerveau	3 paramètres réglés sur les 60 cas d'entraînement

5.1 M1 : nnU-Net

nnU-Net [4] n'est pas un modèle pré-entraîné contrairement à WMH-SynthSeg (M2) mais un système qui configure automatiquement un réseau de type U-Net à partir des données. À partir des résolutions, des tailles et des intensités des images, il en déduit un prétraitement, la taille des patches et l'architecture du réseau. Il est ensuite entraîné à partir de poids aléatoires sur notre jeu d'entraînement. On utilise la variante à encodeur résiduel ResEnc M, recommandée par ses auteurs depuis 2024 [18].

Sur nos données, nnU-Net choisit de travailler à la résolution médiane des FLAIR, soit $3 \times 0{,}98 \times 1$ mm (coupes de 3 mm) et rééchantillonne chaque image sur cette grille. Le réseau voit des patches de $40 \times 224 \times 192$ voxels soit $120 \times 219 \times 192$ mm (qui couvrent presque tout le cerveau) par lots de deux. C'est un U-Net à six étages (figure 1). L'encodeur réduit la résolution étage par étage, de $40 \times 224 \times 192$ à $5 \times 7 \times 6$ voxels, en augmentant le nombre de canaux de 32 à 320 et chaque étage empile des blocs résiduels (de 1 à 6). L'épaisseur des coupes guide deux choix : le premier étage n'utilise que des convolutions dans le plan des coupes ($1 \times 3 \times 3$) et la résolution n'est réduite entre les coupes qu'à partir du troisième étage, une fois la résolution dans le plan devenue comparable. Le décodeur remonte symétriquement jusqu'à la résolution du patch en réutilisant à chaque étage les cartes de l'encodeur de même résolution et produit pour chaque voxel la probabilité d'être une lésion.

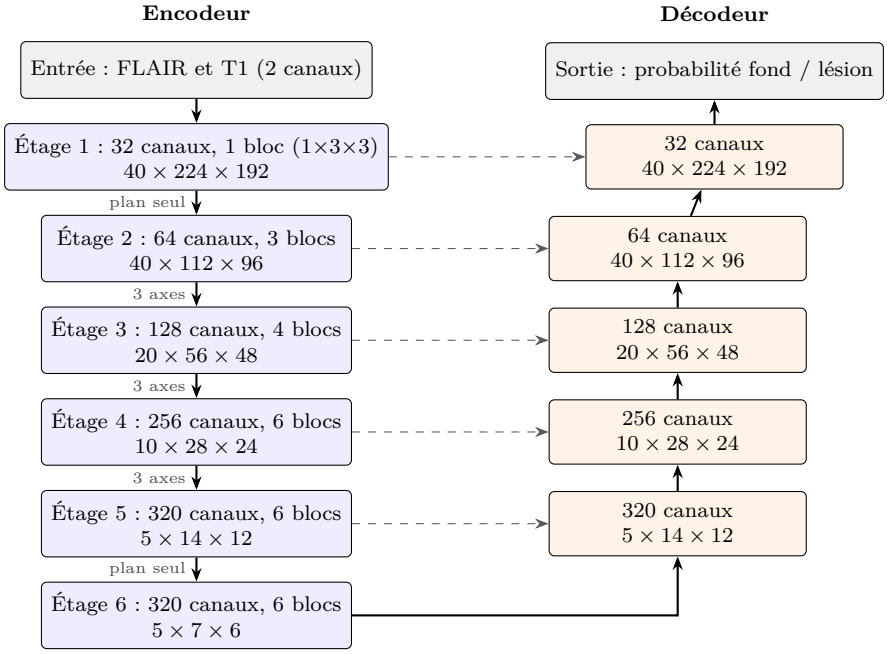


FIGURE 1 – Architecture choisie par nnU-Net (ResEnc M, 3D pleine résolution) ; tailles en voxels (coupes × lignes × colonnes). Chaque bloc résiduel enchaîne deux convolutions $3 \times 3 \times 3$ (sauf au premier étage, $1 \times 3 \times 3$), chacune suivie d'une normalisation d'instance et d'une activation LeakyReLU, et ajoute son entrée à sa sortie. Entre deux étages, la résolution est divisée par deux dans le plan des coupes seul ou selon les trois axes. Le décodeur double la résolution à chaque étage (convolution transposée), concatène les cartes de l'encodeur de même taille (flèches pointillées) puis applique une convolution. Des sorties auxiliaires aux résolutions intermédiaires du décodeur participent aussi à la perte pendant l'entraînement).

Les deux canaux d'entrée sont la FLAIR et la T1 corrigées par N4 avec la T1 rééchantillonnée sur la grille de la FLAIR (section 3). Ensuite nnU-Net fait une normalisation de chaque canal par un z-score propre à chaque image. Les voxels « autre pathologie » (étiquette 2) sont déclarées ignorée et on ne les comptent ni dans la fonction de perte ni dans la validation afin d'être raccord avec l'évaluation officielle. Les autres réglages sont ceux de nnU-Net par défaut avec une perte combinant Dice et entropie croisée et une augmentation de données standard avec un tiers des patches contenant au moins une lésion.

Il a ensuite fallu adapter le budget d'entraînement aux moyens du bord (GPU local de 8 Go de mémoire et quota gratuit de GPU T4 sur Kaggle). Le nombre d'époques a donc été réduit de 1 000 (31 h sur les GPU gratuits de Kaggle) à 250, nnU-Net adaptant automatiquement la décroissance du taux d'apprentissage à la durée totale, ce qui permet de faire tourner l'entraînement en une session (10,5 h). Une stratégie d'entraînement en 5 plis stratifiés par scanner et par charge lésionnelle était initialement prévue, mais afin d'économiser le temps de calcul, un seul pli (48 cas d'entraînement, 12 de validation) a été lancé.

La courbe d'entraînement confirme que ce budget suffit (figure 2). La perte de validation cesse de diminuer vers l'époque 150, alors que celle d'entraînement continue de baisser : au-delà, le modèle s'ajuste davantage aux cas d'entraînement sans progresser sur la validation. Le pseudo-Dice de validation, moyenné au fil des époques, atteint 0,826 à l'époque 50, 0,844 à l'époque 150 et 0,840 à la fin. Ce pseudo-Dice, calculé par nnU-Net sur des patches pendant l'entraînement, est un indicateur interne optimiste ; le Dice des 12 volumes de validation complets est de 0,815.

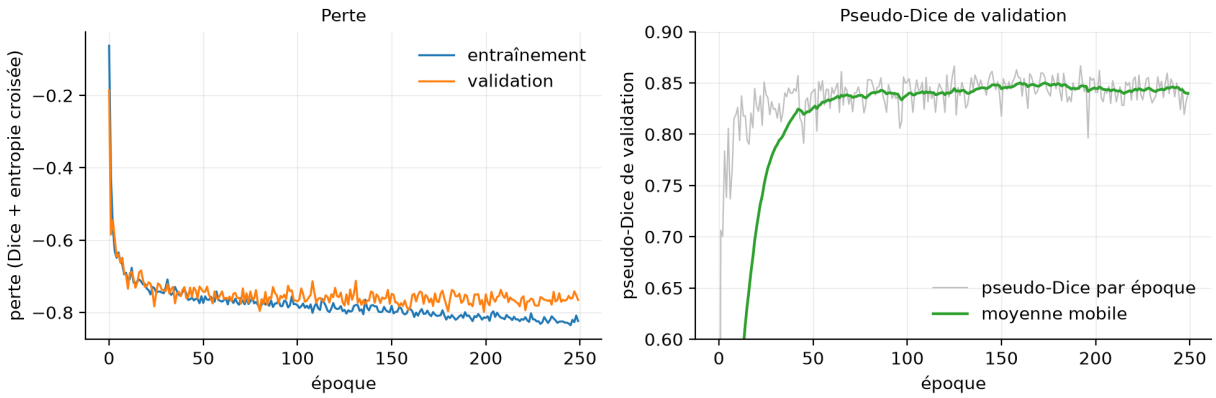


FIGURE 2 – Entraînement de M1 (pli 0, 250 epochs). À gauche, la perte d'entraînement et de validation ; elle est négative parce que nnU-Net soustrait le Dice à l'entropie croisée. À droite, le pseudo-Dice de validation à chaque époque et sa moyenne mobile (0,9× moyenne précédente + 0,1× valeur de l'époque), celle que nnU-Net suit pour garder son meilleur modèle.

L'inférence est faite sur le GPU local en utilisant le moyennage des prédictions des images retournées (*mirroring*) prévu par nnU-Net.

5.2 M2 : WMH-SynthSeg

WMH-SynthSeg [19] est un modèle distribué par FreeSurfer [20] qui segmente à la fois les HSB et l'anatomie du cerveau. Il a été entraîné sur des images synthétiques générées à partir de cartes d'étiquettes avec des contrastes et des résolutions tirés au hasard [21]. Il est ainsi conçu pour fonctionner sur n'importe quelle séquence et n'importe quel scanner sans réentraînement. Il représente ici ce qu'obtient un utilisateur avec un outil publié sans aucune adaptation à ses données.

Il est appliqué à la FLAIR brute, comme le prévoient ses auteurs. Sa sortie se fait sur une grille de 1 mm qui est ramenée sur la grille de la FLAIR par plus proche voisin et l'étiquette des HSB donne le masque des lésions. L'outil demande de 26 à 30 Go de mémoire vive et environ 7 min par patient sur processeur et a été exécuté sur Kaggle. Sa segmentation anatomique sert aussi ailleurs dans ce travail à plusieurs endroits : les tissus du contrôle qualité (section 4) et les ventricules pour distinguer les lésions périventriculaires et profondes (section 7).

5.3 M3 : seuillage

Les HSB sont par définition plus claires que la substance blanche en FLAIR. La méthode la plus simple garde donc les voxels dont l'intensité dépasse un seuil. Elle sert de référence basse et mesure à quel point une règle d'intensité fixe dépend du scanner. Elle s'applique à la FLAIR corrigée par N4 en quatre étapes :

1. l'intensité est convertie en z-score robuste dans le masque du cerveau avec la médiane et l'écart absolu médian, que les lésions brillantes déplacent beaucoup moins que la moyenne et l'écart type
2. les voxels dont le z-score dépasse un seuil t sont retenus
3. les voxels situés à moins de e mm du bord du cerveau sont écartés car ce bord contient beaucoup de voxels clairs qui ne sont pas des lésions (cortex, vaisseaux, volume partiel), alors que les HSB sont profondes (sur les cas d'entraînement 95 % des voxels de lésion d'un patient sont à plus de 16 mm du bord) ;
4. les composantes connexes de moins de m mm^3 sont supprimées avec la taille en mm^3 pour garder le même sens sur toutes les grilles.

Un seul triplet (t, e, m) est choisi pour tous les scanners par une recherche exhaustive sur 1 674 combinaisons qui maximise le Dice moyen des 60 cas d'entraînement. Le réglage retenu est $t = 2{,}2$, $e = 14$ mm et $m = 40$ mm^3 pour un Dice d'entraînement de 0,585. À titre d'information le meilleur seuil propre à chaque scanner varie de 1,7 à Singapour à 2,4 à Amsterdam et 2,6 à Utrecht : les lésions sont moins contrastées à Singapour et une règle unique pénalise ce site. Maximiser le Dice favorise aussi les grandes valeurs de e et m, au détriment des petites lésions, ce que montrera le rappel lésionnel (section 6).

5.4 Normalisation d'intensité pour le seuillage (M3)

Une intensité d'IRM n'a pas d'unité standard donc le seuil de M3 n'a de sens que si toutes les images sont ramenées sur une échelle commune. Quatre normalisations de la FLAIR sont comparées, toutes calculées dans le masque du cerveau :

- **aucune** : l'image est divisée par une constante unique (la médiane des cerveaux d'entraînement) c'est le témoin qui montre ce qu'apporte une normalisation propre à chaque image
- **z-score robuste** : celui de M3 avec la médiane et l'écart absolu médian du cerveau ;
- **WhiteStripe** [22] : l'idée est que le pic principal de l'histogramme du cerveau correspond à la substance blanche, l'image est centrée et réduite avec la moyenne et l'écart type d'une bande étroite de voxels autour de ce pic
- **appariement d'histogrammes** [23] : les centiles du cerveau de chaque image sont alignés par morceaux linéaires sur une échelle standard apprise sur l'entraînement.

Pour chacune de ces normalisation la recherche des paramètres (t, e, m) est refaite sur l'entraînement avec une grille de seuils adaptée à son échelle, puis la segmentation est évaluée sur le test. Les résultats sont présentés avec les autres expériences annexes en section 6.5.

5.5 Variantes de M1

Deux variantes de M1 ont pu tester la sensibilité du modèle à ses choix d'entraînement et de prétraitement.

- **Augmentation forte (DA5).** Un second modèle est entraîné avec les mêmes réglages et le même budget mais avec la variante DA5 de nnU-Net qui applique des transformations d'intensité et de forme plus nombreuses et plus intenses. La question est de savoir si une augmentation plus agressive améliore la généralisation aux scanners inconnus.
- **Prétraitement des organisateurs.** Le modèle principal, entraîné sur notre prétraitement, est appliqué aux images prétraitées par les organisateurs (SPM12 et elastix), pour mesurer la sensibilité de la segmentation au prétraitement (section 3).

Leurs résultats sont présentés en section 6.5.

6 Évaluation

Les trois méthodes sont évaluées sur les 110 cas de test contre la référence O1. Le calcul utilise le script officiel du challenge repris sans modification pour que les chiffres soient directement comparables au classement publié. Les variantes de M1 (DA5 et prétraitement des organisateurs) et de M3 (aucun, z-score, WhiteStripe et appariement d'histogrammes) sont des expériences annexes. Elles sont évaluées de la même façon mais ne font pas partie de l'étude centrale. Leurs résultats principaux sont rapportés en section 6.5 et en annexe C.

Chaque comparaison répond à une question précise et les tests statistiques sont regroupés par question, on parle de famille de tests (tableau 5). Une famille rassemble toutes les comparaisons faites pour répondre à une même question (sur les cinq métriques). C'est à l'intérieur d'une famille que l'on corrige pour les comparaisons multiples (section 6.2).

TABLE 5 – Questions de l'évaluation et familles de tests correspondantes, en trois catégories. Le nombre de tests est le nombre de comparaisons multiplié par le nombre de métriques (cinq, ou les trois métriques symétriques pour le plafond humain). La correction de Holm est appliquée dans chaque famille. Pour les normalisations les tests par méthode portent sur WhiteStripe, l'appariement d'histogrammes et l'absence de normalisation ; le z-score (M3) relève de l'étude centrale.

Famille	Question	Méthodes comparées	Tests
Étude centrale			
Comparaison des méthodes	Comment se comparent un modèle spécialisé, un modèle publié et une règle classique ? (section 6.3)	M1, M2, M3 deux à deux	15
Scanners inconnus	M1, M2 et M3 sont-ils moins bons sur les scanners inconnus ? (section 6.4)	M1, M2, M3 vus contre inconnus	15
Effet du scanner	Les performances de M1, M2 et M3 dépendent-elles du scanner ? (section 6.4)	M1, M2, M3 entre les 5 scanners	15
Expériences annexes			
Augmentation forte (DA5)	Une augmentation plus forte améliore-t-elle M1 ? (section 6.5)	M1, M1 DA5	5
Généralisation de DA5	Le gain de DA5 est-il plus grand sur les scanners inconnus que sur les vus ? (section 6.5)	gain DA5 − M1, inconnus contre vus	5
Prétraitement des organisateurs	M1 dépend-il de notre prétraitement ? (sections 3.3 et 6.5)	M1, M1 sur les images des organisateurs	5
Normalisation : comparaison	Quelle normalisation d'intensité pour le seuillage ? (section 6.5)	M3 avec 4 normalisations, deux à deux	30
Normalisation : effet du scanner	Le seuillage dépend-il du scanner selon la normalisation ? (section 6.5)	3 normalisations entre les 5 scanners	15
Plafond humain			
M1 contre experts	M1 atteint-il le niveau des experts ? (section 6.6)	M1 contre O3 et contre O4, 12 cas	6

6.1 Métriques

La mesure d'une bonne segmentation se fait dans le cadre de ce challenge par le biais de 5 métriques (moyenné sur l'ensemble des patients), couvrant des aspects différents de la qualité d'une segmentation :

- le **Dice** mesure le recouvrement voxel à voxel entre la segmentation et la référence et va de de 0 (aucun voxel commun) à 1 (identité)
- la **distance de Hausdorff à 95 %** (HD95, en mm) mesure l'écart entre les contours des deux segmentations, elle est sensible aux erreurs éloignées des lésions comme une fausse détection isolée et est asymétrique sur la référence (on calcul les deux sens et on garde la pire)
- la **différence de volume absolue** (AVD, en %) est l'erreur sur le volume total de lésions rapportée au volume de référence
- le **rappel lésionnel** est la part des lésions de la référence touchées par la segmentation (au sens 26-connexes, sans pondération sur la taille des lésions)
- le **F1 lésionnel** combine ce rappel et la précision lésionnelle c'est à dire la part des lésions

détectées qui correspondent à une vraie lésion.
Une petite lésion manquée change à peine le Dice mais compte autant qu'une grande dans le rappel, d'où l'importance d'avoir plusieurs axes de métriques. Les voxels « autre pathologie » (étiquette 2) sont retirés de la segmentation avant chaque calcul. Les formules sont données en annexe C.

6.2 Méthodes statistiques

Avec 10 à 30 patients par scanner un écart entre deux moyennes peut venir simplement des patients. Chaque résultat est donc accompagné d'une mesure d'incertitude ou d'un test, choisis selon la question posée.

— **Incertitude d'une moyenne.** L'intervalle de confiance à 95 % est calculé par un bootstrap [24] (2 000 tirages avec remise) on recalcule la moyenne à chaque fois et l'intervalle va du 2,5^{e} au 97,5^{e} centile de ces moyennes. Le tirage est stratifié par scanner afin de garder la composition du test (30, 30, 30, 10 et 10 patients).

— **Comparaison de deux méthodes.** Toutes les méthodes sont appliquées aux mêmes patients puis on calcule la différence par appariement entre patient (ça retire de la métrique la difficulté propre à chaque patient). La différence moyenne reçoit un intervalle de confiance par bootstrap et le test de Wilcoxon signé [25] dit si elle peut être due au hasard en comparant les rangs des écarts positifs et négatifs sans supposer de loi normale.

— **Scanners vus contre inconnus.** Les 90 patients des scanners vus à l'entraînement et les 20 des scanners inconnus sont des patients différents donc on ne peut pas travailler sur la comparaison appariée. La différence des moyennes reçoit un intervalle par bootstrap et le test de Mann-Whitney [26] compare les deux distributions.

— **Effet du scanner.** Le test de Kruskal-Wallis [27] qui généralise le test de Mann-Whitney à plus de deux groupes, compare les cinq scanners pour une méthode et une métrique.

— **Comparaisons multiples.** Les tests sont regroupés en familles, une par question (tableau 5). Au seuil de 5 %, près d'un test sur les 15 de l'étude centrale sortirait significatif par hasard même sans aucune différence réelle. La correction de Holm [28] contrôle ce risque à l'intérieur de chaque famille. Elle offre la même garantie que la correction de Bonferroni en étant moins sévère. Séparer les familles évite qu'une expérience annexe alourdisse la correction de l'étude centrale et inversement.

Le détail des procédures est donné en annexe C.

6.3 Comparaison des méthodes

M1 obtient un Dice de 0,802 sur le test nettement au-dessus de M3 (0,595) et de M2 (0,402) et il est le meilleur des trois sur les cinq métriques (tableau 6). Pour situer ces résultats chaque méthode est insérée seule dans le classement officiel des 57 équipes publiées du challenge. Ce classement ramène chaque métrique entre 0 pour la meilleure équipe et 1 pour la pire, puis fait la moyenne des cinq. M1 se place 9e sur 58, pour une équipe gagnante à 0,81 de Dice. Il est 2e au Dice et au F1 lésionnel et 1er à l'AVD mais seulement 22e au rappel lésionnel. Comme son Dice et son volume restent très bons on en déduit que les lésions manquées sont surtout petites, c'est son point faible.

Table 6 – Métriques officielles sur les 110 cas de test : moyenne et intervalle de confiance à 95 % (bootstrap stratifié par scanner), et position dans le classement du challenge (58 équipes avec la méthode insérée).

Méthode	Dice ↑	HD95 (mm) ↓	AVD (%) ↓	Rappel lésionnel ↑	F1 lésionnel ↑	Classement
M1 nnU-Net	**0,802** [0,784 ; 0,820]	**6,1** [4,8 ; 7,7]	**15** [13 ; 18]	**0,728** [0,709 ; 0,746]	**0,783** [0,768 ; 0,798]	**9e**
M2 WMH-SynthSeg	0,402 [0,361 ; 0,444]	14,0 [12,6 ; 15,4]	293 [208 ; 392]	0,428 [0,400 ; 0,458]	0,451 [0,431 ; 0,471]	55^{e}
M3 seuillage	0,595 [0,560 ; 0,631]	22,7 [21,0 ; 24,3]	73 [52 ; 97]	0,229 [0,209 ; 0,248]	0,284 [0,268 ; 0,301]	55^{e}

Les comparaisons appariées confirment que ces écarts ne sont pas dus au hasard des patients.

Les 15 tests sont significatifs après correction de Holm avec des p corrigés inférieurs à 10^{-11} (tableau 7). M1 est meilleur que M2 et que M3 sur chacune des cinq métriques. M2 et M3, tous deux 55e au classement, ne se dominent pas l'un et l'autre. Leurs différences sont significatives mais dans des sens opposés. Le seuillage est meilleur au Dice (0,595) et à l'AVD mais ne trouve que 23 % des lésions. Une explication possible est qu'en maximisant le Dice, son réglage a écarté les petites composantes et les voxels proches du bord du cerveau (section 5). WMH-SynthSeg est meilleur au HD95, au rappel (43 % des lésions trouvées) et au F1 lésionnels au prix d'une forte sur-segmentation. Il prédit en médiane deux fois le volume de la référence, d'où une AVD de 293 %. Une explication possible (non vérifiée) est que sa définition des HSB, apprise sur d'autres annotations, est plus large que celle des experts du challenge.

Table 7 – Comparaisons appariées de l'étude centrale sur les 110 cas de test : différence moyenne A − B avec intervalle de confiance à 95 % (bootstrap stratifié par scanner) et en dessous le p du test de Wilcoxon signé après correction de Holm sur les 15 tests de l'étude centrale. Un signe positif favorise A pour le Dice, le rappel et le F1, et B pour le HD95 et l'AVD.

Métrique	M1 − M3	M1 − M2	M3 − M2
Dice	+0,208 [0,185 ; 0,230] $p = 1 \times 10^{-18}$	+0,400 [0,370 ; 0,428] $p = 1 \times 10^{-18}$	+0,193 [0,167 ; 0,217] $p = 4 \times 10^{-15}$
HD95 (mm)	−16,6 [−18,2 ; −14,8] $p = 4 \times 10^{-17}$	−7,9 [−9,0 ; −6,7] $p = 1 \times 10^{-16}$	+8,7 [7,0 ; 10,3] $p = 4 \times 10^{-13}$
AVD (points)	−57 [−79 ; −37] $p = 4 \times 10^{-13}$	−278 [−376 ; −198] $p = 6 \times 10^{-17}$	−221 [−310 ; −142] $p = 1 \times 10^{-11}$
Rappel lésionnel	+0,500 [0,472 ; 0,525] $p = 1 \times 10^{-18}$	+0,301 [0,269 ; 0,331] $p = 6 \times 10^{-17}$	−0,199 [−0,222 ; −0,176] $p = 1 \times 10^{-17}$
F1 lésionnel	+0,500 [0,478 ; 0,521] $p = 1 \times 10^{-18}$	+0,332 [0,315 ; 0,350] $p = 1 \times 10^{-18}$	−0,167 [−0,191 ; −0,144] $p = 3 \times 10^{-16}$

6.4 Effet du scanner et scanners inconnus

Deux questions portent sur le scanner : les performances varient-elles d'un scanner à l'autre (test de Kruskal-Wallis entre les cinq scanners) et sont-elles moins bonnes sur les deux scanners absents de l'entraînement (test de Mann-Whitney) ? Les cinq métriques n'y répondent pas de la même façon. Le tableau 8 les détaille pour M1, le reste est en annexe C.

Table 8 – M1 par scanner sur les 110 cas de test (extrait des tableaux C.3, C.5 et C.6 de l'annexe) : moyenne de chaque métrique, p du test de Kruskal-Wallis entre les cinq scanners, et différence entre scanners inconnus et vus avec le p du test de Mann-Whitney, tous deux après correction de Holm. Les deux scanners marqués d'un astérisque sont absents de l'entraînement.

Métrique	Utrecht (30)	Singapour (30)	Ams. GE 3T (30)	Ams. Philips 3T* (10)	Ams. GE 1,5T* (10)	Effet du scanner (p corrigé)	Inconnus − vus (p corrigé)
Dice	0,786	0,834	0,796	0,776	0,804	1	−0,015 (1)
HD95 (mm)	7,3	4,4	5,1	8,6	8,4	0,098	+2,9 (1)
AVD (%)	18	14	15	17	11	1	−1 (1)
Rappel lésionnel	0,638	0,748	0,783	0,674	0,833	2×10^{-7}	+0,031 (1)
F1 lésionnel	0,715	0,795	0,829	0,773	0,831	2×10^{-5}	+0,023 (1)

Le Dice et l'AVD de M1 ne dépendent pas du scanner ($p = 1$ après correction). C'est le résultat le plus utile pour la suite car le volume de lésions est le biomarqueur principal (section 7), ici on montre qu M1 le mesure avec la même justesse sur tous les sites.

Le HD95 varie davantage, de 4,4 mm à Singapour à 8,6 mm sur Amsterdam Philips 3T mais sans effet significatif du scanner ($p = 0{,}098$ après correction). Les moyennes élevées viennent de

quelques patients à très faible charge lésionnelle. Sur les scanners inconnus, les trois HD95 les plus élevés (de 30 à 41 mm) concernent des patients ayant moins de 2,5 ml de lésions, chez qui une seule fausse détection éloignée suffit à faire monter le 95e centile des distances.

Le rappel et le F1 lésionnels sont les seules métriques qui dépendent du scanner ($p = 2 \times 10^{-7}$ et $p = 2 \times 10^{-5}$ après correction). M1 trouve 64 % des lésions de la référence à Utrecht contre 83 % sur Amsterdam GE 1,5T. Cet écart ne s'explique pas par la taille des lésions, Utrecht est le site qui compte le moins de petites lésions et l'effet du scanner persiste une fois la taille médiane des lésions prise en compte. Son origine n'est pas établie, le style de délimitation de la référence, qui peut varier d'un site à l'autre, ou les différences d'images entre scanners sont des pistes possibles.

Sur les scanners inconnus M1 n'est moins bon sur aucune métrique ($p = 1$ après correction pour les cinq), son Dice y est de 0,790 contre 0,805 sur les scanners vus, une différence de $-0{,}015$ dont l'intervalle de confiance, $[-0{,}066; +0{,}030]$, contient zéro.

Ces résultats ne démontrent pas de dégradation hors domaine mais ne prouvent pas non plus son absence car avec 20 patients l'intervalle reste large. Les 20 patients viennent en outre de deux scanners seulement tous deux à Amsterdam et faute de données démographiques un écart pourrait refléter la population autant que le scanner.

M2 et M3 suivent le même schéma (annexe C) : leur Dice, leur HD95 et leur AVD ne dépendent pas du scanner, leur rappel lésionnel si et aucune de leurs métriques ne diffère entre scanners vus et inconnus après correction. Le seuillage M3 fait même un peu mieux sur les scanners inconnus (Dice de 0,622 contre 0,589), que son z-score recalculé sur chaque image rend peu sensibles au scanner.

6.5 Expériences annexes

Normalisation du seuillage. Le tableau 9 résume les quatre normalisations décrites en section 5. Les comparaisons appariées et l'effet du scanner sur les cinq métriques sont en annexe C.

TABLE 9 – Seuillage (M3) selon la normalisation d'intensité de la FLAIR : Dice moyen sur les 110 cas de test, sur les scanners vus à l'entraînement (90 cas) et inconnus (20 cas) et test de Kruskal-Wallis de l'effet du scanner sur le Dice, avant et après correction de Holm dans la famille de chaque méthode (étude centrale pour le z-score, normalisation pour les trois autres)

Normalisation	Dice	Dice vus	Dice inconnus	Effet du scanner	p corrigé
Aucune	0,203	0,209	0,173	$p < 10^{-16}$	$p < 10^{-15}$
z-score robuste (M3)	0,595	0,589	0,622	$p = 0{,}90$	$p = 1$
WhiteStripe	**0,611**	0,607	0,628	$p = 0{,}93$	$p = 1$
Appariement d'histogrammes	0,522	0,531	0,479	$p = 0{,}51$	$p = 1$

Sans normalisation propre à chaque image le seuillage s'effondre et son résultat dépend entièrement du scanner ($p < 10^{-16}$, $p < 10^{-15}$ après correction), un résultat plutôt normal. Avec les trois normalisations par image le test ne détecte plus aucun effet du scanner (p de 0,51 à 0,93, $p = 1$ après correction). Cohérent avec le fait qu chaque normalisation ramène les images sur une échelle commune. WhiteStripe est la meilleure devant le z-score (intervalle de confiance du gain de Dice [0,010 ; 0,024], $p = 0{,}0005$) (annexe C). L'appariement d'histogrammes est la moins bonne et sur-segmente, une explication est qu'en imposant la même distribution d'intensités à tous les cerveaux il déforme le contraste des lésions dont la part dans le cerveau varie fortement d'un patient à l'autre. Pour la suite de ce travail M3 garde le z-score qui est la référence classique. Le gain de WhiteStripe est réel mais modeste.

Augmentation forte (DA5). Le modèle entraîné avec DA5 obtient un Dice de 0,798 contre 0,802 pour M1, et ne s'en distingue sur aucune métrique (p corrigés de 0,59 à 1, annexe C). Sur les scanners inconnus son Dice est de 0,790 comme celui de M1, et son gain sur M1 n'est pas plus grand sur les scanners inconnus que sur les scanners vus (écart de +0,006, intervalle de confiance

$[-0{,}002; +0{,}014]$, test de Mann-Whitney $p = 0{,}36$, $p = 0{,}73$ après correction). Le premier modèle, avec l'augmentation par défaut, reste le modèle principal.

Prétraitement des organisateurs. Appliqué aux images prétraitées par les organisateurs, M1 obtient un Dice de 0,803 contre 0,802 sur nos images (différence de $-0{,}001$, $p = 1$ après correction), et aucune métrique ne diffère (p corrigés de 0,35 à 1 ; annexe C). La segmentation ne dépend donc pas de notre prétraitement (section 3.3).

6.6 Plafond inter-observateurs

La référence O1 est elle-même la délimitation d'un expert et deux experts ne délimitent jamais exactement les mêmes lésions. Les experts O3 et O4, qui ont délimité indépendamment les 60 cas d'entraînement donnent le niveau atteignable par un humain. Contre O1 ils obtiennent un Dice de 0,770 et 0,785 et entre eux 0,759.

Les 12 cas de validation de l'entraînement de M1 qu'il n'a jamais vus, sont les seuls où le modèle et les experts peuvent être comparés sur les mêmes images (tableau 10). M1 y obtient un Dice de 0,815 contre 0,757 pour O3 et 0,781 pour O4, et dépasse O3 sur 10 patients sur 12 et O4 sur 9. Avec 12 patients ces écarts ne sont pas significatifs et le test de Wilcoxon donne $p = 0{,}027$ contre O3 et $p = 0{,}052$ contre O4 et aucune différence ne résiste à la correction de Holm sur les six comparaisons (deux experts, trois métriques symétriques), les p corrigés valent 0,16 et 0,26 pour le Dice (contre O3 et O4), 1 et 1 pour le HD95, 0,61 et 1 pour le F1 lésionnel. Les intervalles de confiance du Dice excluent zéro (par exemple [0,015 ; 0,108] contre O3, annexe C), mais ils ne sont pas corrigés pour les six comparaisons et avec quatre patients par scanner le bootstrap sous-estime l'incertitude : on retient la conclusion du test corrigé, qui ne permet pas d'affirmer une différence.

Table 10 – Accord avec la référence O1 sur les 12 cas de validation de M1 jamais vus par le modèle. La dernière ligne compare les deux experts indépendants entre eux.

Contre O1 (12 cas)	Dice	HD95 (mm)	F1 lésionnel
M1 nnU-Net	**0,815**	**4,3**	**0,762**
Expert O3	0,757	5,7	0,721
Expert O4	0,781	4,9	0,760
O4 contre O3	0,740	8,0	0,763

M1 se situe donc au niveau des experts. Ce n'est pas pour autant « mieux qu'un expert » car M1 a appris le style de délimitation de O1 contre lequel il est jugé alors que O3 et O4 suivent leurs propres conventions (bord des lésions, petites lésions). Ces 12 cas viennent par ailleurs tous de scanners vus à l'entraînement.

7 Biomarqueurs

Dans la section 6 on a mis l'accent sur la segmentation voxel par voxel, on s'intérèsse maintenant aux biomarqueurs qui sont des métriques plus proche de la réalité terrain des étude clinique, en particulier le volume de lésions. Dans le cadre d'une étude multicentrique il faut pouvoir garantir un biomarqueur sans biais. On se demande alors si le volume mesuré automatiquement est aussi juste que celui d'un expert et si son erreur est la même sur tout les site.

7.1 Définitions

Les biomarqueurs sont calculés pour chaque patient et chaque source de segmentation (O1, M1, M2, M3 et les experts O3 et O4 sur les cas d'entraînement) après retrait des zones « autre pathologie » :

— **volume de HSB** (ml) : le volume total de HSB calculé avec la taille exact d'un voxel selon le scanner (1,75 à 4,72 mm^3)
— **fraction du volume intracrânien** (%) : rapport entre le volume de HSB et le volum intracrânien (masque issu de WMH-SynthSeg)
— **volumes périventriculaire et profond** (ml) : un voxel de HSB est périventriculaire s'il se trouve à 10 mm ou moins des ventricules latéraux (segmentés par WMH-SynthSeg), sinon il est profond
— **nombre de lésions** : composantes connexes (voisinage des 26 voxels) d'au moins 10 mm^3 afin de rendre le compte comparable entre des grilles de résolutions différentes

Le volume médian est de 11,2 ml (0,8 à 195 ml) sur la référence O1 et varie d'un site à l'autre. La médiane est de 6,3 ml à Amsterdam GE 3T contre 15,9 ml à Singapour (annexe D). Ces écarts reflètent les populations recrutées par chaque centre.

7.2 Accord avec la référence

Chaque source (M1, M2 et M3 sur les 110 cas de test et les experts O3 et O4 sur les 60 cas d'entrainement) est comparée patient par patient à O1 qui est notre référence humaine. Comme les volumes vont de moins de 1 à près de 200 ml et que l'erreur croît avec le volume on travaille sur le rapport source / O1, c'est-à-dire sur la différence des logarithmes.

On utilise deux outis pour mesurer l'accord, la méthode de Bland-Altman [29] et l'ICC [30]. Bland-Altman donne un biais (rapport moyen à O1) qui mesure si une source mesure trop ou trop peur en moyenne ainsi que des limites d'accord ($2{,}5^{e}$ et $97{,}5^{e}$ centilles de l'erreur sur l'ensemble des patients). L'ICC mesure la part de la variabilité due aux vraies différences entre patients plutôt qu'aux erreurs de mesure et contrairement à une corrélation il pénalise un écart systématique. Les formules sont en annexe D.

Table 11 – Accord du volume de HSB avec la référence O1. Biais, limites d'accord, ICC d'accord absolu sur le logarithme du volume avec intervalle de confiance à 95 % (bootstrap stratifié par scanner). La dernière colonne est le test de Kruskal-Wallis de l'effet du site sur le biais avec p corrigé par Holm.

Source	Biais	Limites d'accord	ICC [IC 95 %]	Biais dépendant du site (p)
M1 nnU-Net (test, 110)	0,98	[0,54 ; 1,31]	0,982 [0,975 ; 0,988]	0,0034
M2 WMH-SynthSeg (test, 110)	2,44	[0,70 ; 16,3]	0,372 [0,281 ; 0,469]	0,44
M3 seuillage (test, 110)	1,18	[0,38 ; 6,14]	0,814 [0,740 ; 0,872]	0,0035
Expert O3 (entraînement, 60)	0,97	[0,61 ; 1,47]	0,981 [0,968 ; 0,989]	0,0036
Expert O4 (entraînement, 60)	0,91	[0,57 ; 1,61]	0,977 [0,965 ; 0,986]	0,0027

M1 mesure le volume aussi bien qu'un second expert (tableau 11) avec un rapport moyen de 0,98 mais des limites d'accord assez large allant de 0,54 à 1,31 et un ICC de 0,982. Son erreur est asymétrique (figure 3) et on peut voir qu'il surestime rarement de plus de 30 % mais sous-estime fortement quelques patients, surtout parmi les faibles volumes où quelques lésions manquées pèsent lourd dans le rapport. Les limites d'accord restent larges même entre experts ce qui donne la marge réaliste de la mesure d'un volume de HSB. Sur les 12 cas de validation (les seuls où M1 et les experts sont jugés sur les mêmes patients) (tableau D.4), M1 sous-estime un peu plus le volume que les experts (rapport de 0,87 contre 0,93 et 0,95), mais de façon bien plus régulière (son rapport reste entre 0,69 et 1,05), quand celui de O3 va de 0,41 à 1,50 et celui de O4 de 0,64 à 1,77 et son ICC est le plus élevé (0,990 contre 0,976).

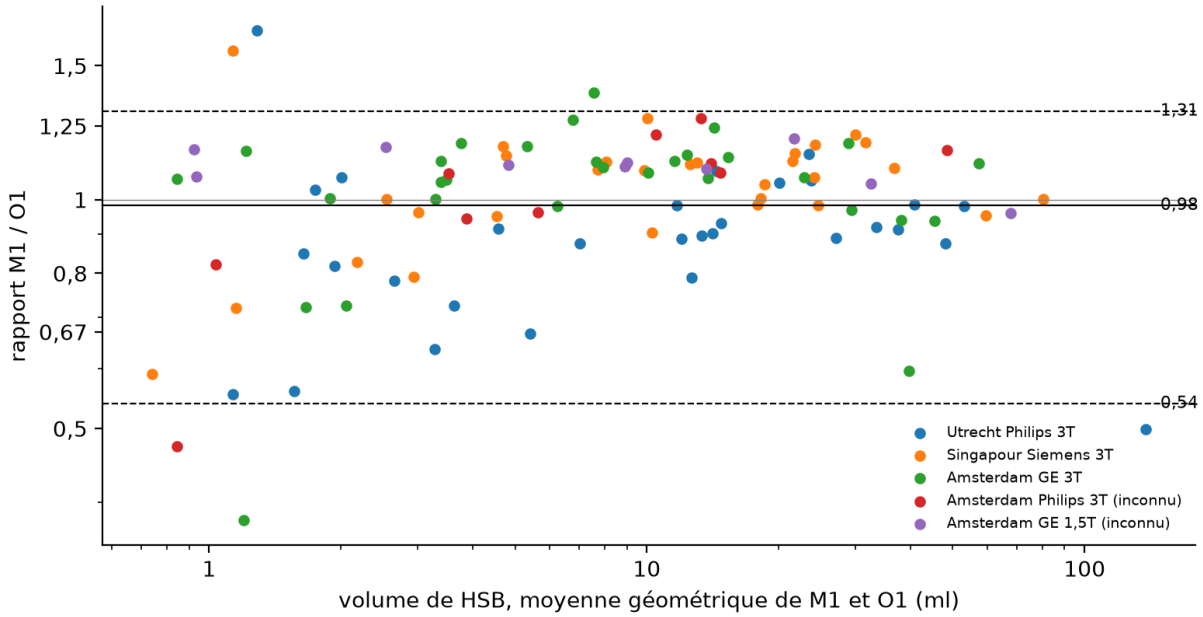


FIGURE 3 – Bland-Altman du volume de HSB de M1 contre O1 sur les 110 cas de test, en échelle logarithmique. Trait plein : biais moyen. Tirets : limites d'accord (2,5^{e} et 97,5^{e} centiles).

M3 est juste en moyenne mais imprécis patient par patient (rapport moyen de 1,18, limites de 0,38 à 6,1, ICC de 0,81). M2 surestime le volume d'un facteur 2,4 (ICC de 0,37) et n'est pas utilisable comme biomarqueur sur ce protocole d'annotation.

Les autres biomarqueurs (annexe D) confirment ce classement et ajoutent deux nuances. M1 les sous-estime les lésions profondes de 13 % (rapport de 0,87, ICC de 0,964) contre un accord parfait en moyenne pour les périventriculaires (1,00, ICC de 0,982). Les experts les sous-estiment aussi (0,86 et 0,78), on peut donc imaginer que c'est O1 qui en délimite d'avantage. M1 compte également environ 18 % de lésions de moins que O1 (ICC de 0,89) ce qui est au niveau des experts (0,85 et 0,88) alors que M3tombe à 0,31 car elle écarte les petites lésions.

7.3 Biais par site

Pour savoir si l'erreur dépend du site on teste pour chaque source si le biais diffère entre les scanners (test de Kruskal-Wallis sur les rapports par patient) et sur chaque scanner si le biais diffère de zéro (test de Wilcoxon) avec une correction de Holm (annexe D).

Le biais de M1 dépend du site ($p = 0{,}0034$ après correction), il sous-estime d'environ 13 % à Utrecht et surestime d'environ 10 % sur Amsterdam GE 1,5T mais ces écarts ne restent pas significatifs scanner par scanner après correction ($p = 0{,}053$ et $p = 0{,}18$). Ce résultat complète celui de la section 6.4 où l'AVD de M1 ne dépendait pas du scanner, or l'AVD mesure l'ampleur de l'erreur de volume sans son signe, contrairement au biais qui garde la trace du signe. C'est donc le sens de l'erreur qui change d'un site à l'autre.

Le biais de M3 dépend aussi du site (surestimation de 72 % à Utrecht) alors que celui de M2 n'en dépend pas ($p = 0{,}44$). Sa surestimation est la même sur tous les scanners (de 1,9 à 3,3 fois le volume de O1). Les experts ont eux aussi des biais de site. O4 sous-estime de 20 % à Singapour ($p = 0{,}0018$). Une partie du biais de site d'une méthode reflète donc le style de délimitation de la référence sur certains sites. Sans données démographiques, un biais associé au site peut en outre venir de la population autant que du scanner.

7.4 Cartes de fréquence lésionnelle

Pour vérifier que les lésions sont trouvées aux bons endroits chaque masque est transporté dans l'espace commun MNI (section 3), puis on calcule en chaque voxel la proportion de patients qui y ont une lésion. La carte d'une méthode est comparée à celle de O1 sur les mêmes patients par la corrélation de Pearson voxel à voxel et des cartes de différence montrent où se situent les écarts.

La carte de M1 corrèle à 0,995 avec celle de O1 (de 0,97 à 0,99 selon le site) comme celles des experts O3 et O4 (0,993 et 0,992 sur les cas d'entraînement). M3 et M2 descendent à 0,90 et 0,88, et M2 à 0,67 sur Amsterdam GE 1,5T. Les cartes de différence (figure 4) semblent indiquer que l'excès de M2 forme un liseré le long des ventricules et que le seuillage manque des lésions dans la substance blanche profonde et ajoute de faux positifs le long de la ligne médiane, tandis que les écarts de M1 restent faibles et dispersés.

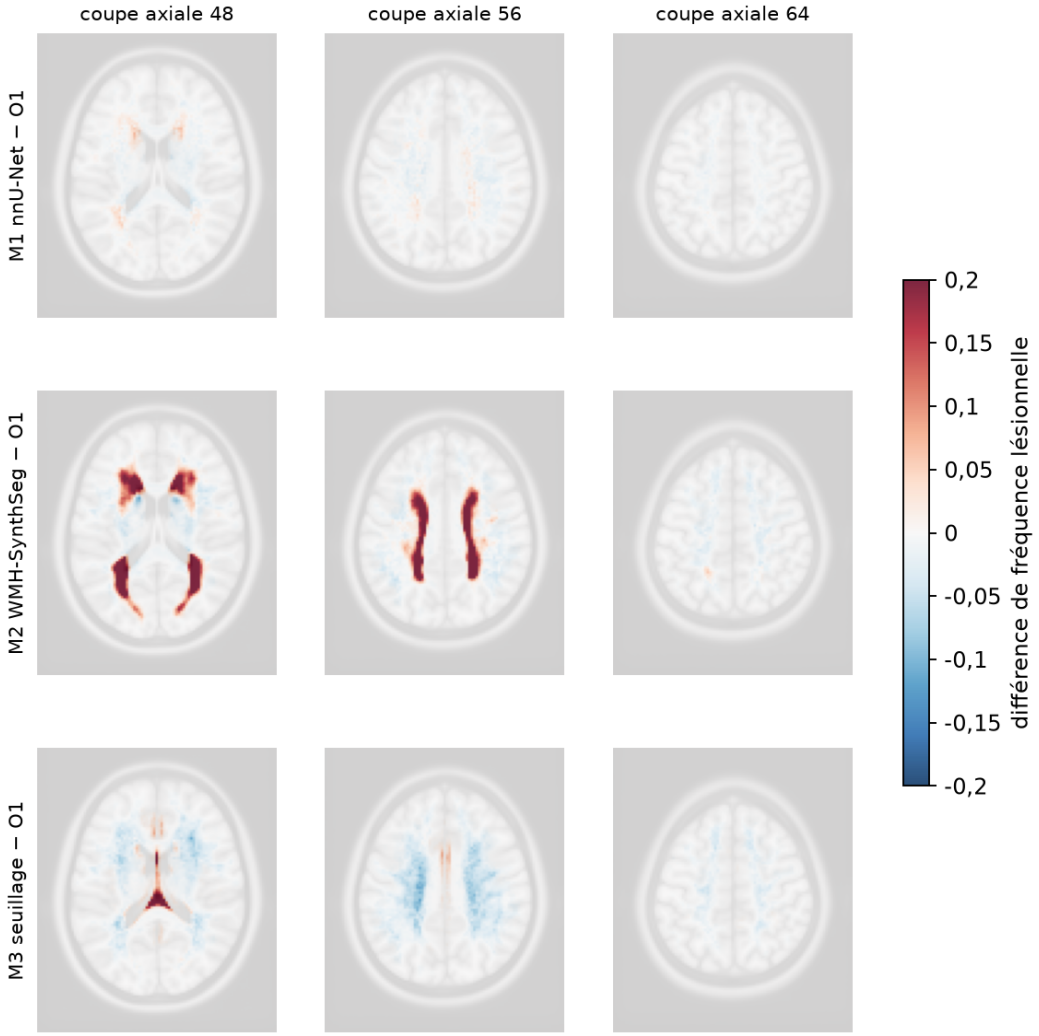


FIGURE 4 – Différence entre la carte de fréquence lésionnelle de chaque méthode et celle de O1 (dans l'espace MNI) sur les 110 cas de test (trois coupes axiales passant par les ventricules latéraux). En rouge les régions où la méthode trouve des lésions chez plus de patients que O1 et en bleu chez moins.

8 Harmonisation des mesures multicentriques

La section 6.5 a montré qu'une normalisation propre à chaque image suffit à rendre le seuillage indépendant du scanner. Cependant dans une étude multicentrique on peut également comparer

des mesures tirées directement des images comme l'intensité ou la texture des tissus. Cette section vise à savoir si la normalisation d'intensité retire totalement l'empreinte du scanner et si ComBat permet un gain sur l'effacement des empreintes sans effacer le signal biologique.

8.1 Signature de site

Les mesures étudiées sont 20 caractéristiques de la substance blanche d'apparence saine. Pour chaque modalité (FLAIR et T1 corrigées par N4) les caractéristiques retenus se composent de cinq centiles de son intensité, son écart interquartile, son asymétrie et son aplatissement, la médiane du cortex et le contraste entre cortex et substance blanche. Les tissus viennent de la segmentation de WMH-SynthSeg qui donne aux HSB leur propre étiquette que l'on retire à la substance blanche mesurée. WMH-SynthSeg tend à surestimer les HSB ce qui nous arrange dans ce cas précis. Elles sont calculées sans normalisation (une constante par modalité pour tous les patients) et après le z-score robuste par image de M3 (section 5).

L'empreinte du scanner est mesurée de deux façons. Un classifieur de site (régression logistique sur les 20 caractéristiques) cherche à deviner le scanner de chaque patient. On utilise une validation croisée à 5 plis stratifiés par scanner. S'il y parvient bien plus souvent que le hasard (20 % avec cinq scanners), les mesures portent la signature du site. Pour chaque caractéristique, la part de sa variance expliquée par le scanner (η^2) dit ensuite quelle part de ses différences entre patients vient en réalité du site.

Sans normalisation le classifieur devine le scanner de 90 % des patients et le site explique en moyenne 71 % de la variance des caractéristiques (tableau 12). Le z-score par image réduit cette empreinte sans la supprimer, on devine encore le scanner 73 % des patients et le site explique encore 21 % de la variance. La normalisation aligne le niveau et l'échelle des intensités, ce qui suffit au seuillage, mais laisse la forme de l'histogramme et le contraste propres à chaque scanner. En particulier l'asymétrie et l'aplatissement de la substance blanche en T1 gardent la plus forte signature (figure 5).

8.2 ComBat

ComBat [7, 8] modélise chaque caractéristique comme la somme d'un effet biologique, d'un décalage propre au site et d'un facteur d'échelle propre au site, puis retire ces deux effets de site. Les paramètres de chaque site sont estimés par une approche bayésienne empirique, qui partage l'information entre les caractéristiques et stabilise l'estimation pour les petits sites (10 patients pour les deux scanners inconnus). Les variables biologiques à protéger sont déclarées au modèle pour que leur effet ne soit pas retiré avec le site. Ici on a pris la charge lésionnelle ($\ln(1+$volume de HSB$)$) et le volume intracrânien. Le modèle est l'implémentation neuroHarmonize [31] appliquée au z-score par image ou aux intensités brutes.

Pour ne pas surestimer son effet, ComBat ne doit jamais voir les patients sur lesquels on le juge. Il est donc appris à l'intérieur de la validation croisée. Dans chaque pli, il est appris sur les seuls patients d'entraînement puis appliqué tel quel aux patients de test sur lesquels le classifieur essaie de deviner le scanner. Le découpage du challenge (60 cas d'entraînement, 110 de test) ne pouvait pas servir ici. ComBat estime en effet une correction propre à chaque site à partir de ses patients, or les deux scanners inconnus n'ont aucun patient d'entraînement. Les plis de la validation croisée, stratifiés par scanner, contiennent au contraire des patients des cinq scanners.

Après ComBat le classifieur ne devine plus le scanner que de 28 % des patients et le site n'explique plus que 2 % de la variance en moyenne contre 21 % avant (tableau 12). Le résultat est le même sans normalisation préalable (29 % et 2 %). ComBat retire aussi l'empreinte que la normalisation laissait, et aucune caractéristique ne garde plus de 4 % de variance due au site (figure 5).

TABLE 12 – Signature de site des 20 caractéristiques de la substance blanche saine, avant et après ComBat (170 patients, cinq scanners). Scanner deviné : précision équilibrée du classifieur de site en validation croisée à 5 plis (moyenne ± écart type entre les plis). Variance due au site : η^2 moyen des 20 caractéristiques. Lien avec la charge lésionnelle : $|\rho|$ de Spearman moyen entre chaque caractéristique et ln(1 + volume de HSB).

Caractéristiques	Scanner deviné	Variance due au site	Lien avec la charge
Sans normalisation	90 % (± 6 %)	71 %	0,24
Sans normalisation + ComBat	29 % (± 6 %)	2 %	0,28
z-score robuste par image	73 % (± 8 %)	21 %	0,40
z-score robuste par image + ComBat	**28 %** (± 4 %)	**2 %**	**0,44**

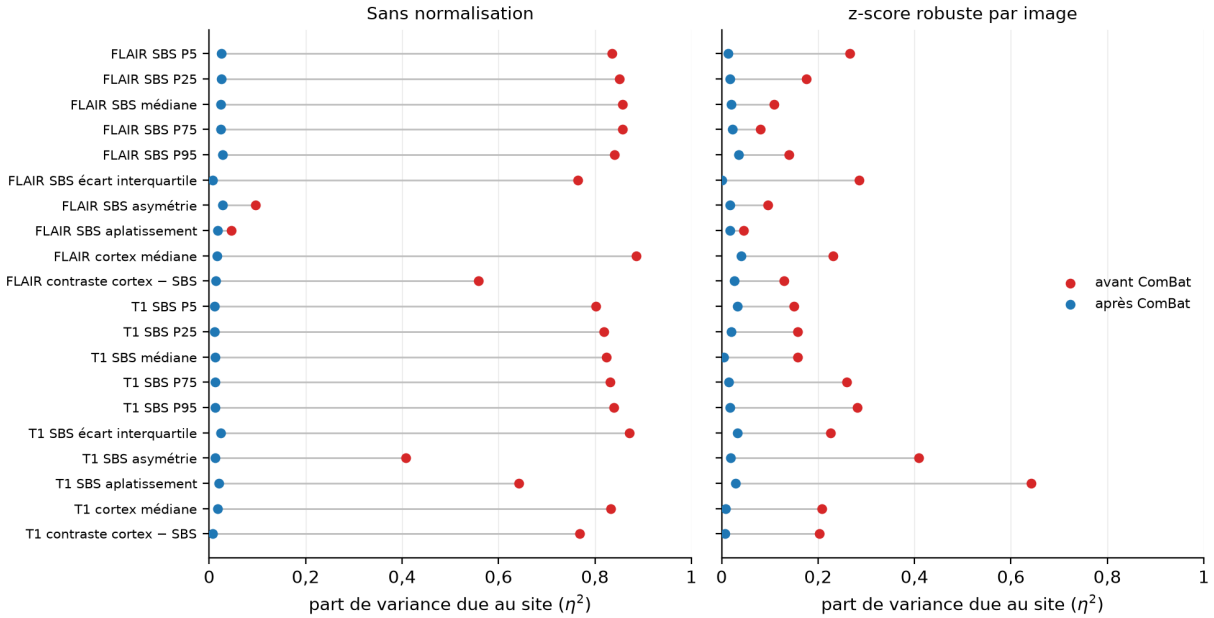


FIGURE 5 – Part de la variance de chaque caractéristique de la substance blanche saine (SBS) expliquée par le scanner, avant et après ComBat, sans normalisation et après le z-score robuste par image.

8.3 Conservation de la biologie

Retirer l'effet du site n'a d'intérêt que si le signal biologique reste. On mesure donc pour chaque caractéristique sa corrélation de Spearman avec la charge lésionnelle, avant et après ComBat. Ici le lien est conservé et même un peu renforcé avec un $|\rho|$ moyen de 0,40 avant et 0,44 après ComBat pour le z-score par image (0,24 et 0,28 sans normalisation). Le bruit du site masquait une partie du signal que l'on récupère une fois retiré..

Ce résultat doit être lu avec deux réserves. D'abord, la charge lésionnelle est justement l'une des covariables protégées. ComBat est construit pour conserver son lien avec les caractéristiques et ce contrôle vérifie surtout qu'il le fait correctement, pas qu'il préserverait une biologie qu'on ne lui aurait pas désignée. Faute de données démographiques aucun autre signal (l'âge, par exemple) ne permet de le vérifier. Pour ce contrôle, ComBat est en outre appris sur les 170 patients à la fois. Ensuite la covariable vient de la segmentation manuelle de O1 mais dans une vraie étude elle viendrait d'une segmentation automatique, dont le biais dépend lui-même du site (section 7).

9 Reproductibilité

Toute la chaîne, des images brutes téléchargées aux tableaux de ce rapport, a été est écrite pour être relancée à l'identique. Les versions des bibliothèques, les règles du workflow et les principaux paramètres sont en annexe F.

9.1 Workflow et environnement

Workflow. La chaîne complète est décrite dans un workflow Snakemake [32] de 25 règles, du téléchargement des données aux figures : prétraitement, contrôle qualité, segmentation, évaluation, biomarqueurs, cartes MNI et harmonisation. Chaque règle déclare ses entrées et ses sorties et Snakemake ne relance que ce qui manque ou dont une entrée a changé. Les deux étapes exécutées sur Kaggle, faute de puissance suffisante en local (entraînements de nnU-Net et WMH-SynthSeg), sont déclarées comme des étapes externes et si leurs sorties manquent le workflow s'arrête en indiquant le carnet à lancer. Les étapes coûteuses ne sont relancées que si leurs sorties disparaissent pour qu'une simple réécriture de tableau ne déclenche jamais un nouvel entraînement.

Paramètres. Tous les paramètres (chemins, seuils, grilles de recherche, nombre de tirages bootstrap, familles de tests) sont réunis dans un seul fichier de configuration, et toutes les étapes aléatoires utilisent une graine fixée. Le recalage rigide est rendu déterministe (section 3). Deux exécutions donnent donc les mêmes chiffres.

Environnement. Les dépendances Python sont figées par le gestionnaire uv dans un fichier de verrouillage qui fixe la version exacte de chaque bibliothèque, y compris les dépendances indirectes. Le code est organisé en paquet, testé par 164 tests automatiques qui tournent sur de petites images synthétiques sans données réelles ni accès réseau. À chaque modification du dépôt, une intégration continue (GitHub Actions) réinstalle l'environnement verrouillé, vérifie le style du code et relance tous les tests.

Données. Les données du challenge ne sont pas redistribuées, leur licence (CC BY-NC 4.0) ne le permettant pas. Un script les télécharge depuis DataverseNL et vérifie l'empreinte de chaque fichier puis les convertit au format BIDS (section 3). Le dépôt ne contient que des résultats agrégés, aucune image de patient.

9.2 Conteneurs et calcul intensif

Pour s'affranchir du système d'exploitation la chaîne est aussi fournie sous forme de conteneurs. Une même recette Docker produit deux images à partir de l'environnement verrouillé. Une image sur processeur, légère, pour toutes les étapes sauf l'apprentissage profond et une image sur GPU qui ajoute nnU-Net et HD-BET. L'intégration continue construit l'image sur processeur à chaque modification et vérifie qu'elle importe la chaîne et lance ses commandes.

Le principal compromis de ce travail vient du calcul car un seul pli de nnU-Net a été entraîné en 250 époques (section 5), faute de GPU suffisant. Entraîner les cinq plis et les combiner, comme le recommande nnU-Net, demanderait un calculateur doté de plusieurs GPU.

10 Discussion et conclusion

10.1 Synthèse

Ce travail cherchait à répondre à quatre questions sur des images venant de cinq scanners différents. Les réponses sont plus nuancées qu'un simple oui ou non et elles tiennent souvent autant à la référence et aux données qu'aux méthodes elles-mêmes.

Le contrôle qualité inspiré de MRIQC et adapté à la FLAIR remplit en partie son rôle. Sur les images réelles du challenge les images qu'il signale ne sont pas moins bien segmentées (Dice médian de 0,820 contre 0,825), ce qui s'explique par la présélection des organisateurs et par la robustesse de nnU-Net. Sur les images dégradées volontairement il repère presque toutes les segmentations

dégradées par le bruit ou le champ de biais (78 sur 83) et pour le champ de biais avant même que le Dice ne décroche. En revanche il laisse passer la plupart des segmentations dégradées par le mouvement (76 sur 99) et une bonne partie de celles dégradées par les images fantômes (24 sur 40) et sa détection du mouvement dépend fortement du scanner.

Pour la segmentation le modèle entraîné sur ces données (M1) se détache nettement. Avec un Dice de 0,802 il se place 9e sur 58 au classement du challenge et il est meilleur que le modèle publié (M2) et que le seuillage (M3) sur les cinq métriques. Son point faible reste les petites lésions, il ne retrouve que 73 % des lésions de la référence et ce rappel varie d'un scanner à l'autre (de 64 % à Utrecht à 83 % sur Amsterdam GE 1,5T). Sur les deux scanners absents de l'entraînement aucune dégradation n'est démontrée et sur les 12 cas où il peut être comparé aux experts il se situe à leur niveau. Ni une augmentation de données plus forte ni le prétraitement des organisateurs ne changent ces résultats. WMH-SynthSeg utilisé sans adaptation prédit en médiane deux fois le volume de la référence, ce qui rappelle qu'un outil généraliste doit être vérifié sur les données et sur la définition des lésions propres à chaque étude.

Le volume de lésions mesuré par M1 est aussi fiable que celui d'un second expert (ICC de 0,982 contre 0,981 et 0,977) et ses lésions sont placées aux mêmes endroits que celles de la référence (corrélation des cartes de 0,995). Son biais dépend toutefois du site, comme celui des experts. Une partie de ce qu'on appellerait un biais de site vient donc de la référence elle-même et de la façon dont elle a été délimitée sur chaque site, ce qui limite ce qu'on peut attendre d'une méthode automatique jugée contre elle.

Enfin une normalisation d'intensité propre à chaque image suffit à rendre le seuillage indépendant du scanner mais elle ne retire qu'une partie de l'empreinte du scanner dans les mesures de la substance blanche saine (le scanner est encore deviné pour 73 % des patients). ComBat appris en validation croisée ramène cette empreinte près du hasard (28 % pour un hasard de 20 %) sans affaiblir le lien avec la charge lésionnelle.

10.2 Limites

La première limite vient du calcul. Un seul pli de nnU-Net a été entraîné, en 250 époques et sans ensemble de modèles alors que nnU-Net recommande d'en combiner cinq. Les performances de M1 sont donc probablement un peu en dessous de ce que la méthode permet.

La deuxième tient à la taille des groupes. La généralisation hors domaine repose sur 20 patients de deux scanners, tous les deux à Amsterdam, et l'intervalle de confiance de l'écart de Dice va de $-0{,}066$ à $+0{,}030$. Le résultat ne démontre pas de dégradation mais n'en prouve pas non plus l'absence et des scanners d'autres centres ou d'autres constructeurs pourraient se comporter autrement. De la même façon la comparaison aux experts ne porte que sur 12 cas (tous de scanners vus à l'entraînement) et M1 a appris le style de délimitation de O1 contre lequel il est jugé.

La troisième vient des données disponibles. Le challenge ne fournit aucune donnée démographique donc un écart entre sites peut venir de la population autant que du scanner. Pour la même raison la conservation de la biologie après ComBat n'a pu être vérifiée que sur la charge lésionnelle, qui fait partie des covariables protégées et non sur un signal indépendant comme l'âge. Sur le test une seule référence (O1) est disponible et tous les résultats en dépendent.

Enfin le contrôle qualité a été validé sur des artefacts simulés avec TorchIO à partir d'images déjà présélectionnées. Ces artefacts ne reproduisent qu'en partie les défauts réels et le mouvement (qui est l'artefact le plus nuisible) est aussi celui que le contrôle détecte le moins bien en FLAIR.

10.3 Perspectives

Plusieurs prolongements découlent directement de ces limites. Sur un calculateur doté de plusieurs GPU on pourrait entraîner les cinq plis de nnU-Net et les combiner, puis vérifier si l'ensemble améliore surtout le rappel des petites lésions qui est le point faible actuel. Le contrôle qualité gagnerait à intégrer des indicateurs plus spécifiques du mouvement et des images fantômes

et pourrait apprendre à partir des artefacts simulés quelle combinaison d'indicateurs annonce une segmentation dégradée plutôt que de s'en tenir à des seuils sur chaque indicateur.

La chaîne étant entièrement automatisée et indépendante du jeu de données, elle pourrait aussi être appliquée à une cohorte plus large avec plus de sites, plus de constructeurs et des données démographiques. Cela permettrait de tester la généralisation sur des scanners réellement nouveaux, de séparer l'effet du site de celui de la population et de vérifier que ComBat préserve un signal biologique qu'on ne lui a pas désigné, comme l'âge.

10.4 Conclusion

Ce travail propose une chaîne reproductible qui va des images brutes aux biomarqueurs harmonisés sur les données multicentriques du challenge MICCAI WMH 2017. Il montre qu'un modèle nnU-Net entraîné avec un budget modeste segmente les HSB au niveau des experts, sans dégradation démontrée sur des scanners inconnus et qu'il fournit un volume de lésions aussi fiable qu'un second expert. Il montre aussi que les difficultés multicentriques ne disparaissent pas pour autant. Le biais de mesure dépend du site (y compris pour les experts), l'empreinte du scanner reste dans les intensités après normalisation et seule une harmonisation comme ComBat la retire. Le mouvement échappe en grande partie au contrôle qualité. Dans une étude multicentrique la segmentation n'est donc qu'une étape et la qualité des images, la référence et l'harmonisation doivent être contrôlées au même titre.

Références

[1] Joanna M. Wardlaw, Eric E. Smith, Geert J. Biessels et al. "Neuroimaging standards for research into small vessel disease and its contribution to ageing and neurodegeneration". In : *The Lancet Neurology* 12.8 (2013), p. 822-838. doi : 10.1016/S1474-4422(13)70124-8.

[2] Stéphanie Debette et Hugh S. Markus. "The clinical importance of white matter hyperintensities on brain magnetic resonance imaging : systematic review and meta-analysis". In : *BMJ* 341 (2010), p. c3666. doi : 10.1136/bmj.c3666.

[3] Franz Fazekas et al. "MR signal abnormalities at 1.5 T in Alzheimer's dementia and normal aging". In : *American Journal of Roentgenology* 149.2 (1987), p. 351-356. doi : 10.2214/ajr.149.2.351.

[4] Fabian Isensee et al. "nnU-Net : a self-configuring method for deep learning-based biomedical image segmentation". In : *Nature Methods* 18.2 (2021), p. 203-211. doi : 10.1038/s41592-020-01008-z.

[5] Oscar Esteban et al. "MRIQC : Advancing the automatic prediction of image quality in MRI from unseen sites". In : *PLoS ONE* 12.9 (2017), e0184661. doi : 10.1371/journal.pone.0184661.

[6] Hugo J. Kuijf, J. Matthijs Biesbroek, Jeroen De Bresser et al. "Standardized assessment of automatic segmentation of white matter hyperintensities and results of the WMH segmentation challenge". In : *IEEE Transactions on Medical Imaging* 38.11 (2019), p. 2556-2568. doi : 10.1109/TMI.2019.2905770.

[7] W. Evan Johnson, Cheng Li et Ariel Rabinovic. "Adjusting batch effects in microarray expression data using empirical Bayes methods". In : *Biostatistics* 8.1 (2007), p. 118-127. doi : 10.1093/biostatistics/kxj037.

[8] Jean-Philippe Fortin, Drew Parker, Birkan Tunç et al. "Harmonization of multi-site diffusion tensor imaging data". In : *NeuroImage* 161 (2017), p. 149-170. doi : 10.1016/j.neuroimage.2017.08.047.

[9] Stefan Klein et al. “elastix : a toolbox for intensity-based medical image registration”. In : *IEEE Transactions on Medical Imaging* 29.1 (2010), p. 196-205. doi : 10.1109/TMI.2009.2035616.

[10] John Ashburner et Karl J. Friston. “Unified segmentation”. In : *NeuroImage* 26.3 (2005), p. 839-851. doi : 10.1016/j.neuroimage.2005.02.018.

[11] Krzysztof J. Gorgolewski, Tibor Auer, Vince D. Calhoun et al. “The brain imaging data structure, a format for organizing and describing outputs of neuroimaging experiments”. In : *Scientific Data* 3 (2016), p. 160044. doi : 10.1038/sdata.2016.44.

[12] Brian B. Avants et al. “Symmetric diffeomorphic image registration with cross-correlation : evaluating automated labeling of elderly and neurodegenerative brain”. In : *Medical Image Analysis* 12.1 (2008), p. 26-41. doi : 10.1016/j.media.2007.06.004.

[13] Fabian Isensee, Marianne Schell, Irada Pflueger et al. “Automated brain extraction of multisequence MRI using artificial neural networks”. In : *Human Brain Mapping* 40.17 (2019), p. 4952-4964. doi : 10.1002/hbm.24750.

[14] Nicholas J. Tustison, Brian B. Avants, Philip A. Cook et al. “N4ITK : improved N3 bias correction”. In : *IEEE Transactions on Medical Imaging* 29.6 (2010), p. 1310-1320. doi : 10.1109/TMI.2010.2046908.

[15] Vladimir Fonov et al. “Unbiased average age-appropriate atlases for pediatric studies”. In : *NeuroImage* 54.1 (2011), p. 313-327. doi : 10.1016/j.neuroimage.2010.07.033.

[16] Fei Tony Liu, Kai Ming Ting et Zhi-Hua Zhou. “Isolation forest”. In : *IEEE International Conference on Data Mining (ICDM)*. 2008, p. 413-422. doi : 10.1109/ICDM.2008.17.

[17] Fernando Pérez-García, Rachel Sparks et Sébastien Ourselin. “TorchIO : a Python library for efficient loading, preprocessing, augmentation and patch-based sampling of medical images in deep learning”. In : *Computer Methods and Programs in Biomedicine* 208 (2021), p. 106236. doi : 10.1016/j.cmpb.2021.106236.

[18] Fabian Isensee et al. “nnU-Net Revisited : A Call for Rigorous Validation in 3D Medical Image Segmentation”. In : *Medical Image Computing and Computer Assisted Intervention (MICCAI)*. T. 15009. Lecture Notes in Computer Science. 2024, p. 488-498.

[19] Pablo Laso, Stefano Cerri et al. “Quantifying white matter hyperintensity and brain volumes in heterogeneous clinical and low-field portable MRI”. In : *IEEE International Symposium on Biomedical Imaging (ISBI)*. 2024. doi : 10.1109/ISBI56570.2024.10635502.

[20] Bruce Fischl. “FreeSurfer”. In : *NeuroImage* 62.2 (2012), p. 774-781. doi : 10.1016/j.neuroimage.2012.01.021.

[21] Benjamin Billot, Douglas N. Greve, Oula Puonti et al. “SynthSeg : Segmentation of brain MRI scans of any contrast and resolution without retraining”. In : *Medical Image Analysis* 86 (2023), p. 102789. doi : 10.1016/j.media.2023.102789.

[22] Russell T. Shinohara, Elizabeth M. Sweeney, Jeff Goldsmith et al. “Statistical normalization techniques for magnetic resonance imaging”. In : *NeuroImage : Clinical* 6 (2014), p. 9-19. doi : 10.1016/j.nicl.2014.08.008.

[23] László G. Nyúl, Jayaram K. Udupa et Xuan Zhang. “New variants of a method of MRI scale standardization”. In : *IEEE Transactions on Medical Imaging* 19.2 (2000), p. 143-150. doi : 10.1109/42.836373.

[24] Bradley Efron et Robert J. Tibshirani. *An Introduction to the Bootstrap*. New York : Chapman & Hall, 1993.

[25] Frank Wilcoxon. “Individual comparisons by ranking methods”. In : *Biometrics Bulletin* 1.6 (1945), p. 80-83. doi : 10.2307/3001968.

[26] Henry B. Mann et Donald R. Whitney. “On a test of whether one of two random variables is stochastically larger than the other”. In : *The Annals of Mathematical Statistics* 18.1 (1947), p. 50-60. doi : 10.1214/aoms/1177730491.

[27] William H. Kruskal et W. Allen Wallis. “Use of ranks in one-criterion variance analysis”. In : *Journal of the American Statistical Association* 47.260 (1952), p. 583-621. doi : 10.1080/01621459.1952.10483441.

[28] Sture Holm. “A simple sequentially rejective multiple test procedure”. In : *Scandinavian Journal of Statistics* 6.2 (1979), p. 65-70.

[29] J. Martin Bland et Douglas G. Altman. “Measuring agreement in method comparison studies”. In : *Statistical Methods in Medical Research* 8.2 (1999), p. 135-160. doi : 10.1177/096228029900800204.

[30] Kenneth O. McGraw et S. P. Wong. “Forming inferences about some intraclass correlation coefficients”. In : *Psychological Methods* 1.1 (1996), p. 30-46. doi : 10.1037/1082-989X.1.1.30.

[31] Raymond Pomponio, Guray Erus, Mohamad Habes et al. “Harmonization of large MRI datasets for the analysis of brain imaging patterns throughout the lifespan”. In : *NeuroImage* 208 (2020), p. 116450. doi : 10.1016/j.neuroimage.2019.116450.

[32] Felix Mölder, Kim Philipp Jablonski, Brice Letcher et al. “Sustainable data analysis with Snakemake”. In : *F1000Research* 10 (2021), p. 33. doi : 10.12688/f1000research.29032.1.

[33] Olaf Dietrich et al. “Measurement of signal-to-noise ratios in MR images : influence of multichannel coils, parallel imaging, and reconstruction filters”. In : *Journal of Magnetic Resonance Imaging* 26.2 (2007), p. 375-385. doi : 10.1002/jmri.20969.

[34] Steven D. Forman et al. “Improved assessment of significant activation in functional magnetic resonance imaging (fMRI) : use of a cluster-size threshold”. In : *Magnetic Resonance in Medicine* 33.5 (1995), p. 636-647. doi : 10.1002/mrm.1910330508.

[35] Rastko Ciric, William H. Thompson, Romy Lorenz et al. “TemplateFlow : FAIR-sharing of multi-scale, multi-species brain models”. In : *Nature Methods* 19.12 (2022), p. 1568-1571. doi : 10.1038/s41592-022-01681-2.

Annexes

A Évaluation de la correction du champ de biais

Ressemblance des champs. Pour chaque patient d'entraînement le champ estimé par N4 est comparé à celui de SPM12 (rapport de l'image brute à l'image corrigée par les organisateurs) par la corrélation de leurs logarithmes dans le cerveau. Pour la T1, le champ N4 estimé à 1 mm, est ramené sur la grille de la FLAIR et comparé au champ SPM12 de la T1 alignée (tableau A.1). Les deux méthodes estime globalement un même biais sauf pour la FLAIR de Singapour où SPM12 estime un champ plus faible.

Table A.1 – Corrélation entre les champs de biais estimés par N4 et par SPM12 (médiane sur les 20 cas d'entraînement de chaque scanner).

	Amsterdam, GE 3T	Singapour, Siemens 3T	Utrecht, Philips 3T
FLAIR	0,88	0,74	0,85
T1	0,94	0,97	0,98

Directions du biais. Le biais n'a pas de direction privilégiée commune à tous les scanners. Pour chaque patient la variance du logarithme du champ N4 dans le cerveau est découpée selon chaque axe. En médiane sur les 60 cas, elle vaut 18 % du bas vers le haut, 13 % de gauche à droite et 14 % d'avant en arrière, le reste venant de variations qui combinent plusieurs directions. La direction dominante dépend du scanner : avant-arrière à Amsterdam (50 %), gauche-droite à Singapour (25 %), bas-haut à Utrecht (29 %).

Mesure d'homogénéité. Après une correction réussie un même tissu doit avoir la même luminosité partout dans le cerveau. Pour chacune des trois directions l'image est découpée en plans perpendiculaires à cette direction. Dans chaque plan, on prend le tissu du cerveau (masque HD-BET) sans les lésions ni les zones « autre pathologie » et on relève le 75e centile de son intensité, un repère du niveau de luminosité du tissu peu sensible aux voxels sombres (liquide, bords) et aux valeurs extrêmes. Seuls les plans contenant plus de 2 000 voxels de tissu sont retenus. Le profil obtenu (une valeur par plan) est divisé par sa médiane pour rendre les images comparables quelle que soit leur échelle. La *dispersion* est l'écart type de ce profil, elle vaut zéro si le tissu a la même luminosité dans tous les plans et augmente avec le biais résiduel. Elle est calculée sur trois versions de chaque image : brute, corrigée par SPM12 et corrigée par N4. Mesurer les trois directions évite de privilégier l'une d'elles et en particulier de choisir la direction à partir du champ estimé par N4, ce qui l'avantagerait.

Table A.2 – Dispersion de la luminosité du tissu le long de chaque direction (médiane sur les 60 cas d'entraînement) et nombre de patients pour lesquels N4 fait mieux que SPM12.

Modalité	Direction	Brute	SPM12	N4	N4 meilleur que SPM12
FLAIR	gauche-droite	0,036	0,022	**0,016**	60/60
	avant-arrière	0,032	0,017	**0,010**	54/60
	bas-haut	0,058	0,029	**0,017**	53/60
T1	gauche-droite	0,083	0,070	**0,062**	57/60
	avant-arrière	0,078	0,046	**0,032**	59/60
	bas-haut	0,130	0,079	**0,056**	53/60

Résultats. Les deux corrections réduisent nettement la variation de luminosité et N4 davantage dans les trois directions et pour les deux modalités (tableau A.2). Par scanner le gain de N4 est le plus net là où le biais brut est le plus fort : la FLAIR d'Amsterdam varie surtout d'avant en arrière (dispersion brute de 0,077) et N4 la ramène à 0,009 contre 0,022 pour SPM12, en faisant mieux pour les 20 patients. Les cas les plus serrés concernent Utrecht : la T1 du bas vers le haut où N4 fait mieux pour 13 patients sur 20 seulement, et la FLAIR d'avant en arrière (15 sur 20).

Limites. La mesure est faite dans le masque du cerveau c'est-à-dire dans la région même où N4 a estimé le champ, ce qui le favorise légèrement par rapport à SPM12. Ensuite la dispersion ne descend jamais à zéro même après une correction parfaite car la composition du tissu change d'un plan à l'autre (plus de substance grise dans les coupes hautes, des noyaux gris au centre, etc) ce qui fait varier le 75e centile pour des raisons anatomiques. Cette part touche les deux méthodes de la même façon et ne fausse pas leur comparaison.

B Contrôle qualité : définitions et résultats détaillés

Indicateurs. Les formules sont reprise du code de MRIQC. L'image corrigée par N4 est d'abord multipliée pour que la médiane de la substance blanche vaille 1 000, puis arrondie à l'entier pour les statistiques des tissus, comme dans MRIQC. Pour une région R, on note m_R sa médiane, σ_R son écart type, MAD_R son écart absolu médian (divisé par 0,6745 pour être comparable à un écart type) et n_R son nombre de voxels.

Table B.1 – Indicateurs de qualité (SB : substance blanche, SG : substance grise).

Indicateur	Définition	Meilleur si
SNR	$m_{SB} \,/\, \big(\sigma_{SB}\sqrt{n_{SB}/(n_{SB}-1)}\big)$	élevé
SNR de Dietrich [33]	0,6551 $m_{SB} \,/\, \mathrm{MAD}_{air}$ (le facteur corrige la distribution de Rayleigh du bruit dans l'air)	élevé
CNR	$\lvert m_{SB} - m_{SG}\rvert \,/\, \sqrt{\sigma_{air}^2 + \sigma_{SB}^2 + \sigma_{SG}^2}$	élevé
CJV	$(\mathrm{MAD}_{SB} + \mathrm{MAD}_{SG}) \,/\, \lvert m_{SB} - m_{SG}\rvert$ (T1 seulement)	faible
EFC	$\sum_i \frac{x_i}{b} \ln \frac{x_i}{b} \,/\, \big(\sqrt{N} \ln \frac{1}{\sqrt{N}}\big)$, avec $b = \sqrt{\sum_i x_i^2}$, sur les N voxels non nuls de l'image	faible
FBER	médiane de x^2 dans la tête / médiane de x^2 dans l'air	élevé
Étendue du biais	$\lvert P_{95} - P_5\rvert$ du champ N4 dans le cerveau	faible
FWHM [34]	$\sqrt{-2\ln 2 \,/\, \ln\big(1 - \mathrm{var}(\Delta x)/(2\,\mathrm{var}(x))\big)}$ × taille du voxel, où Δx est la différence entre voxels voisins le long d'un axe, moyennée sur les axes, dans le cerveau de l'image brute	faible

Régions. La substance blanche est l'union des étiquettes de substance blanche de WMH-SynthSeg érodée d'un voxel comme dans MRIQC et privée des hyperintensités et des voxels situés à moins de 2 mm d'une hyperintensité (la substance blanche qui borde une lésion est souvent déjà anormale). La substance grise est le cortex seul non érodé. Il est épais de 2 à 3 mm et il serait presque effacé par une érosion sur la grille de la FLAIR. Les statistiques des tissus sont calculées dans le masque du cerveau HD-BET. La tête est obtenue par un seuil d'Otsu dont on garde la plus grande composante connexe et dont on remplit les trous puis l'air est simplement l'extérieur de la tête dilatée de trois voxels, sans les voxels exactement nuls placés par le scanner ou par le défacement. La T1 est mesurée sur sa propre grille puisque la rééchantillonner lisserait son bruit et gonflerait son rapport signal sur bruit ; les étiquettes de WMH-SynthSeg y sont transportées par l'inverse du recalage rigide. Sur les FLAIR en coupes de 3 mm la FWHM n'est moyennée que sur les deux axes du plan de coupe sinon l'épaisseur de coupe domine la mesure. Le CJV est calculé pour les deux modalités mais jugé sur la T1 seulement parceque en FLAIR le rapport des médianes de la substance blanche et de la substance grise va de 0,87 à 0,99 selon le scanner et le dénominateur du CJV y est presque nul.

Détection. Pour chaque modalité, indicateur et scanner, le z-score robuste vaut $z = (x - \tilde{x})/(1{,}4826\,\mathrm{MAD})$, où $\tilde{x}$ est la médiane du scanner et le facteur 1,4826 rend l'écart absolu médian comparable à un écart type pour des données normales. Le signe est inversé pour les indicateurs dont une valeur élevée est meilleure. Un scanner comptant moins de 8 images n'est pas évalué, sa médiane étant trop instable mais ce n'est le cas d'aucun scanner ici. La forêt d'isolement (500 arbres) isole chaque patient par des coupes aléatoires dans l'espace des z-scores de ses deux modalités, bornés à zéro du côté favorable pour que seuls les écarts défavorables comptent. La proportion attendue d'images atypiques est fixée à 5 %.

Table B.2 – Classes du contrôle qualité par scanner (170 patients).

Scanner	Utilisable	À vérifier	À exclure	Total
Utrecht, Philips 3T	41	5	4	50
Singapour, Siemens 3T	42	7	1	50
Amsterdam, GE 3T	44	6	0	50
Amsterdam, Philips 3T	7	1	2	10
Amsterdam, GE 1,5T	8	1	1	10
Total	142	20	8	170

Parmi les 28 images signalées l'indicateur le plus extrême est l'étendue du biais en FLAIR pour 9 d'entre elles, le rapport signal sur bruit en FLAIR pour 5 et le FBER en FLAIR pour 4. Les autres se répartissent entre le CJV, la FWHM, l'EFC et l'étendue du biais de la T1.

Artefacts simulés. L'image brute est divisée par la médiane du cerveau, dégradée par TorchIO avec une graine fixe puis remise à l'échelle. Les niveaux 1 à 4 sont : pour le bruit un écart type de 0,03, 0,06, 0,10 et 0,15 fois la médiane du cerveau ; pour le mouvement deux mouvements d'au plus 1, 2, 4 et 8 degrés et millimètres ; pour le biais des coefficients polynomiaux de 0,1, 0,2, 0,35 et 0,5 ; pour les images fantômes quatre fantômes d'intensité 0,1, 0,3, 0,6 et 1,0. L'image dégradée est corrigée par N4 avec les réglages de la chaîne, ses indicateurs sont recalculés dans les régions de l'image propre et elle est jugée par rapport aux images propres de son scanner (z-scores et forêt d'isolement ajustée sur ces images). Une image est détectée si elle n'est pas classée utilisable. Pour la segmentation, les mêmes patients reçoivent les mêmes artefacts sur la FLAIR déjà corrigée par N4 qui est l'entrée de M1 (nnU-Net), la T1 restant intacte ; le biais y représente donc un biais résiduel que N4 n'aurait pas retiré. La perte de Dice d'une image dégradée est mesurée par rapport à la segmentation du même patient sans artefact.

Table B.3 – Artefacts simulés sur les mêmes 30 patients de test (6 par scanner) : part des images détectées par le contrôle qualité pour chaque modalité, et segmentation de M1 sur les FLAIR dégradées (moyenne).

Artefact	Niveau	Détection FLAIR	Détection T1	Dice M1	Rappel lésionnel M1
Aucun	0	0 %	0 %	0,79	0,74
Bruit	1	40 %	0 %	0,79	0,70
	2	40 %	40 %	0,77	0,63
	3	67 %	60 %	0,75	0,53
	4	93 %	87 %	0,70	0,42
Mouvement	1	33 %	50 %	0,74	0,58
	2	27 %	7 %	0,70	0,49
	3	23 %	7 %	0,61	0,39
	4	23 %	10 %	0,60	0,36
Champ de biais	1	13 %	13 %	0,79	0,73
	2	97 %	30 %	0,77	0,66
	3	100 %	87 %	0,71	0,55
	4	100 %	100 %	0,54	0,40
Images fantômes	1	3 %	0 %	0,79	0,74
	2	7 %	0 %	0,78	0,71
	3	7 %	30 %	0,74	0,65
	4	53 %	83 %	0,66	0,50

Chaque artefact est surtout détecté par l'indicateur attendu : l'étendue du biais pour le champ de biais, le FBER et l'EFC (FLAIR) ou le rapport signal sur bruit et le CJV (T1) pour le bruit, le

CJV de la T1 pour les images fantômes, et la FWHM pour le mouvement. La FWHM est le seul indicateur à porter la détection du mouvement, elle augmente d'environ 0,5 à 0,6 mm dès le niveau 1 mais ne croît plus avec l'intensité du mouvement et diminue même légèrement. Sa détection dépend en outre fortement du scanner, en FLAIR elle signale 71 % des images en mouvement d'Amsterdam Philips 3T et 54 % de celles d'Amsterdam GE 3T, mais 8 % à Utrecht et aucune à Singapour ni sur Amsterdam GE 1,5T, où la dispersion de la FWHM entre patients est plus grande.

C Évaluation : définitions et résultats détaillés

Cette annexe donne d'abord les définitions des métriques et des tests puis les résultats complets, famille de tests par famille de tests (tableau 5) : l'étude centrale, les expériences annexes et le plafond inter-observateurs.

C.1 Définitions

Métriques. Les métriques sont celles du script officiel du challenge. Pour un patient on note A l'ensemble des voxels de la référence (étiquette 1 de O1) et B celui de la segmentation après retrait des voxels d'étiquette 2, $|\cdot|$ désigne un nombre de voxels.

TABLE C.1 – Définition des cinq métriques officielles.

Métrique	Définition
Dice	$2\,\lvert A \cap B\rvert \,/\, (\lvert A\rvert + \lvert B\rvert)$
HD95	on extrait d'abord le contour de chaque masque en prenant le masque privé de son intérieur coupe par coupe après érosion d'un voxel dans le plan de la coupe. Pour chaque voxel d'un contour on mesure la distance (en mm) au voxel le plus proche de l'autre contour et HD95 est le plus grand des deux 95e centiles (de A vers B et de B vers A).
AVD	$100 \times \big\lvert\, \lvert B\rvert - \lvert A\rvert \,\big\rvert \,/\, \lvert A\rvert$: l'écart relatif au volume de la référence
Rappel lésionnel	les lésions de la référence sont ses composantes connexes (voisinage de 26 voxels) et le rappel est R = nombre de lésions de A touchées par au moins un voxel de B / nombre de lésions de A
F1 lésionnel	précision P = nombre de composantes de B touchant au moins un voxel de A / nombre de composantes de B puis $F1 = 2PR/(P+R)$

Classement. Pour chaque métrique m moyennée sur les 110 cas de test la valeur v d'une équipe est ramenée sur $[0,1]$ par $r_m = (v - v_{\min})/(v_{\max} - v_{\min})$ pour les métriques à minimiser (HD95, AVD) et $r_m = 1 - (v - v_{\min})/(v_{\max} - v_{\min})$ pour les autres, le minimum et le maximum étant pris sur toutes les équipes. Le score est la moyenne des cinq r_m et l'équipe de plus petit score est la première. Une nouvelle équipe peut changer le minimum ou le maximum d'une métrique et donc le score de toutes les autres. Chacune de nos méthodes est donc insérée seule parmi les 57 équipes publiées.

Intervalle de confiance par bootstrap. Pour une méthode et une métrique on tire avec remise dans chaque scanner autant de patients qu'il en contient (30, 30, 30, 10 et 10) et on calcule la moyenne de l'échantillon obtenu. Ce tirage est répété 2 000 fois (graine fixée) puis l'intervalle à 95 % va du 2,5^{e} au 97,5^{e} centile des 2 000 moyennes. Chaque métrique reçoit son propre intervalle. Pour une différence appariée on applique la même procédure aux différences patient par patient et pour une différence entre scanners vus et inconnus, à chacun des deux groupes ce qui revient à un tirage stratifié par scanner.

Test de Wilcoxon signé. Pour deux méthodes appliquées aux mêmes n patients on calcule les différences d_i et on les classe par valeur absolue, du rang 1 (la plus petite) au rang n. La statistique est la somme des rangs des différences positives. Si les deux méthodes se valent chaque différence a autant de chances d'être positive que négative et cette somme reste proche de la moitié du total des rangs. Une somme très grande ou très petite donne un p faible.

Test de Mann-Whitney. Pour deux groupes de patients différents (90 sur les scanners vus, 20 sur les scanners inconnus) la statistique U compte les paires formées d'un patient de chaque groupe dans lesquelles le patient du second groupe a la valeur la plus élevée. Si les deux groupes suivent la même distributio, U est proche de la moitié des 90×20 paires.

Test de Kruskal-Wallis. Il généralise le test de Mann-Whitney à plus de deux groupes, ici les cinq scanners. Tous les patients sont classés selon la métrique puis on regarde si les rangs se répartissent au hasard entre les scanners ou si certains concentrent les bons ou les mauvais rangs. Une valeur p faible signale une métrique qui dépend du scanner. Il est utilisé pour les normalisations du seuillage (section 6.5) avec un test par normalisation.

Correction de Holm. Les m valeurs p d'une famille de tests sont classées par ordre croissant, $p_{(1)} \leq \cdots \leq p_{(m)}$. La k-ième est multipliée par $m - k + 1$ puis chaque valeur corrigée est portée au moins au niveau de la précédente et est plafonnée à 1. Cette procédure garantit que la probabilité d'obtenir au moins un faux positif parmi les tests d'une famille reste inférieure à 5 %. Les familles sont celles du tableau 5 en trois catégories.

C.2 Étude centrale

L'étude centrale compare les trois méthodes M1, M2 et M3 et pose trois questions chacune formant une famille de 15 tests (tableau 5) : quelle méthode est la meilleure (comparaison des méthodes), les méthodes sont-elles moins bonnes sur les scanners inconnus (scanners inconnus) et leurs performances dépendent-elles du scanner (effet du scanner) ? Cette partie rassemble tous ses résultats. D'abord les résultats descriptifs puis les tests de chaque question.

Résultats descriptifs. Moyennes et rangs au classement (tableau C.2) puis détail par scanner (tableau C.3)

TABLE C.2 – Moyenne des métriques officielles sur les 110 cas de test avec intervalle de confiance à 95 % (bootstrap stratifié par scanner) et en dessous rang de la méthode pour cette métrique parmi les 58 équipes (les 57 publiées et la méthode insérée seule). La dernière colonne donne la position au classement global et score (moyenne des cinq métriques ramenées entre 0 pour la meilleure équipe et 1 pour la pire)

Méthode	Dice ↑	HD95 (mm) ↓	AVD (%) ↓	Rappel lésionnel ↑	F1 lésionnel ↑	Classement
M1 nnU-Net	0,802 [0,784 ; 0,820] 2e	6,1 [4,8 ; 7,7] 6e	15 [13 ; 18] 1e	0,728 [0,709 ; 0,746] 22e	0,783 [0,768 ; 0,798] 2e	9e score 0,055
M2 WMH-SynthSeg	0,402 [0,361 ; 0,444] 57e	14,0 [12,6 ; 15,4] 41e	293 [208 ; 392] 56e	0,428 [0,400 ; 0,458] 53e	0,451 [0,431 ; 0,471] 49e	55e score 0,489
M3 seuillage (z-score)	0,595 [0,560 ; 0,631] 51e	22,7 [21,0 ; 24,3] 52e	73 [52 ; 97] 51e	0,229 [0,209 ; 0,248] 58e	0,284 [0,268 ; 0,301] 55e	55e score 0,511

TABLE C.3 – Moyenne des cinq métriques par scanner sur les 110 cas de test et intervalle de confiance à 95 % (bootstrap). Les deux dernières colonnes sont les scanners absents de l'entraînement.

Méthode	Métrique	Utrecht (30)	Singapour (30)	Ams. GE 3T (30)	Ams. Philips 3T (10)	Ams. GE 1,5T (10)
M1 nnU-Net	Dice	0,786 [0,748 ; 0,822]	0,834 [0,803 ; 0,859]	0,796 [0,758 ; 0,828]	0,776 [0,706 ; 0,831]	0,804 [0,745 ; 0,851]
	HD95 (mm)	7,3 [5,1 ; 9,9]	4,4 [2,5 ; 7,2]	5,1 [3,2 ; 7,5]	8,6 [2,8 ; 16,6]	8,4 [2,1 ; 16,7]
	AVD (%)	18 [12 ; 24]	14 [10 ; 19]	15 [11 ; 21]	17 [10 ; 27]	11 [8 ; 15]
	Rappel lésionnel	0,638 [0,600 ; 0,668]	0,748 [0,712 ; 0,782]	0,783 [0,747 ; 0,814]	0,674 [0,593 ; 0,747]	0,833 [0,783 ; 0,873]
	F1 lésionnel	0,715 [0,676 ; 0,748]	0,795 [0,768 ; 0,819]	0,829 [0,806 ; 0,847]	0,773 [0,711 ; 0,826]	0,831 [0,786 ; 0,870]
M2 WMH-SynthSeg	Dice	0,413 [0,332 ; 0,494]	0,495 [0,415 ; 0,577]	0,333 [0,258 ; 0,414]	0,392 [0,262 ; 0,518]	0,309 [0,213 ; 0,401]
	HD95 (mm)	15,6 [12,8 ; 18,4]	12,9 [10,4 ; 15,8]	12,2 [10,3 ; 14,3]	13,7 [8,4 ; 21,2]	17,9 [12,2 ; 24,9]
	AVD (%)	270 [139 ; 460]	173 [80 ; 292]	377 [231 ; 535]	255 [59 ; 510]	512 [84 ; 1 178]
	Rappel lésionnel	0,369 [0,323 ; 0,418]	0,333 [0,285 ; 0,378]	0,551 [0,482 ; 0,622]	0,453 [0,378 ; 0,539]	0,493 [0,391 ; 0,590]
	F1 lésionnel	0,429 [0,387 ; 0,466]	0,408 [0,369 ; 0,449]	0,480 [0,448 ; 0,512]	0,496 [0,452 ; 0,543]	0,518 [0,443 ; 0,582]
M3 seuillage (z-score)	Dice	0,565 [0,479 ; 0,647]	0,584 [0,524 ; 0,639]	0,618 [0,558 ; 0,676]	0,610 [0,493 ; 0,706]	0,634 [0,530 ; 0,729]
	HD95 (mm)	23,3 [20,5 ; 26,3]	21,4 [18,4 ; 24,7]	23,8 [20,4 ; 27,1]	21,5 [19,5 ; 23,7]	22,4 [14,2 ; 32,3]
	AVD (%)	142 [72 ; 219]	48 [34 ; 66]	52 [34 ; 70]	44 [15 ; 87]	32 [21 ; 43]
	Rappel lésionnel	0,262 [0,231 ; 0,296]	0,134 [0,107 ; 0,163]	0,293 [0,245 ; 0,345]	0,201 [0,133 ; 0,290]	0,249 [0,200 ; 0,293]
	F1 lésionnel	0,302 [0,280 ; 0,326]	0,194 [0,165 ; 0,222]	0,335 [0,301 ; 0,372]	0,268 [0,207 ; 0,343]	0,360 [0,305 ; 0,411]

Comparaison des méthodes. Test de Wilcoxon apparié, famille de 15 tests (tableau C.4).

TABLE C.4 – Comparaisons appariées de l'étude centrale sur les 110 cas de test : différence moyenne A − B avec intervalle de confiance à 95 % (bootstrap stratifié par scanner) et en dessous le p du test de Wilcoxon signé après correction de Holm sur les 15 tests. Un signe positif favorise A pour le Dice, le rappel et le F1, et B pour le HD95 et l'AVD.

Métrique	M1 − M3	M1 − M2	M3 − M2
Dice	+0,208 [0,185 ; 0,230] $p = 1 \times 10^{-18}$	+0,400 [0,370 ; 0,428] $p = 1 \times 10^{-18}$	+0,193 [0,167 ; 0,217] $p = 4 \times 10^{-15}$
HD95 (mm)	−16,6 [−18,2 ; −14,8] $p = 4 \times 10^{-17}$	−7,9 [−9,0 ; −6,7] $p = 1 \times 10^{-16}$	+8,7 [7,0 ; 10,3] $p = 4 \times 10^{-13}$
AVD (points)	−57 [−79 ; −37] $p = 4 \times 10^{-13}$	−278 [−376 ; −198] $p = 6 \times 10^{-17}$	−221 [−310 ; −142] $p = 1 \times 10^{-11}$
Rappel lésionnel	+0,500 [0,472 ; 0,525] $p = 1 \times 10^{-18}$	+0,301 [0,269 ; 0,331] $p = 6 \times 10^{-17}$	−0,199 [−0,222 ; −0,176] $p = 1 \times 10^{-17}$
F1 lésionnel	+0,500 [0,478 ; 0,521] $p = 1 \times 10^{-18}$	+0,332 [0,315 ; 0,350] $p = 1 \times 10^{-18}$	−0,167 [−0,191 ; −0,144] $p = 3 \times 10^{-16}$

Les 15 tests sont significatifs après correction (plus grand p corrigé de 1×10^{-11} pour l'AVD de M3 − M2).

Scanners inconnus. Test de Mann-Whitney, famille de 15 tests (tableau C.5).

TABLE C.5 – Scanners inconnus (20 patients) contre scanners vus (90 patients) sur les cinq métriques. Différence des moyennes avec son intervalle de confiance à 95 % (bootstrap stratifié par scanner) et test de Mann-Whitney avant et après correction de Holm sur les 15 tests.

Méthode	Métrique	Vus (90)	Inconnus (20)	Inconnus − vus [IC 95 %]	p	p corrigé
M1 nnU-Net	Dice	0,805	0,790	−0,015 [−0,066 ; 0,030]	0,45	1
	HD95 (mm)	5,6	8,5	+2,9 [−2,1 ; 8,7]	0,96	1
	AVD (%)	16	14	−1 [−6 ; 4]	0,94	1
	Rappel lésionnel	0,723	0,754	+0,031 [−0,017 ; 0,077]	0,17	1
	F1 lésionnel	0,779	0,802	+0,023 [−0,018 ; 0,060]	0,26	1
M2 WMH-SynthSeg	Dice	0,414	0,350	−0,063 [−0,157 ; 0,028]	0,24	1
	HD95 (mm)	13,6	15,8	+2,2 [−2,1 ; 7,5]	0,45	1
	AVD (%)	273	384	+110 [−173 ; 461]	0,79	1
	Rappel lésionnel	0,418	0,473	+0,055 [−0,019 ; 0,129]	0,076	1
	F1 lésionnel	0,439	0,507	+0,068 [0,018 ; 0,116]	0,013	0,19
M3 seuillage (z-score)	Dice	0,589	0,622	+0,034 [−0,056 ; 0,119]	0,51	1
	HD95 (mm)	22,9	22,0	−0,9 [−5,4 ; 4,4]	0,67	1
	AVD (%)	80	38	−42 [−73 ; −11]	0,16	1
	Rappel lésionnel	0,230	0,225	−0,004 [−0,054 ; 0,049]	0,97	1
	F1 lésionnel	0,277	0,314	+0,037 [−0,009 ; 0,084]	0,19	1

Aucun des 15 tests n'est significatif après correction (plus petit p corrigé de 0,19 pour le F1 lésionnel de M2).

Effet du scanner. Test de Kruskal-Wallis, famille de 15 tests (tableau C.6).

TABLE C.6 – Effet du scanner avec test de Kruskal-Wallis entre les cinq scanners pour chaque méthode et chaque métrique. En haut le p brut et en dessous le p après correction de Holm sur les 15 tests de cette famille. Une valeur p faible signale une métrique qui dépend du scanner.

Méthode	Dice	HD95	AVD	Rappel	F1
M1 nnU-Net	0,22	0,011	0,91	1×10^{-8}	2×10^{-6}
	1	0,098	1	2×10^{-7}	2×10^{-5}
M2 WMH-SynthSeg	0,049	0,24	0,12	4×10^{-5}	0,0086
	0,39	1	0,86	4×10^{-4}	0,086
M3 seuillage (z-score)	0,90	0,71	0,64	1×10^{-6}	5×10^{-7}
	1	1	1	1×10^{-5}	6×10^{-6}

Le rappel et le F1 lésionnels dépendent du scanner pour les trois méthodes (sauf le F1 de M2 après correction) alors que le Dice, le HD95 et l'AVD n'en dépendent pas.

C.3 Expériences annexes

Les expériences annexes posent chacune leur propre question (tableau 5). Chaque question forme sa propre famille de tests.

Résultats descriptifs. Moyennes et rangs au classement (tableau C.7) puis détail par scanner (tableau C.8)

TABLE C.7 – Moyenne des métriques officielles sur les 110 cas de test avec intervalle de confiance à 95 % (bootstrap stratifié par scanner) et en dessous le rang de la méthode pour cette métrique parmi les 58 équipes. La dernière colonne donne la position au classement et le score.

Méthode	Dice ↑	HD95 (mm) ↓	AVD (%) ↓	Rappel lésionnel ↑	F1 lésionnel ↑	Classement
Augmentation forte (DA5)						
M1 avec augmentation forte (DA5)	0,798 [0,779 ; 0,815] 4e	6,3 [4,7 ; 8,0] 8e	16 [14 ; 19] 2e	0,727 [0,707 ; 0,744] 22e	0,786 [0,769 ; 0,801] 2e	10e score 0,058
Prétraitement des organisateurs						
M1 sur le prétraitement des organisateurs	0,803 [0,783 ; 0,821] 2e	6,4 [4,9 ; 8,3] 11e	16 [13 ; 19] 1e	0,724 [0,703 ; 0,744] 22e	0,780 [0,762 ; 0,796] 2e	10e score 0,059
Normalisation du seuillage						
M3 avec WhiteStripe	0,611 [0,577 ; 0,646] 49e	22,6 [20,9 ; 24,2] 52e	62 [45 ; 83] 51e	0,222 [0,204 ; 0,242] 58e	0,285 [0,269 ; 0,302] 55e	55e score 0,502
M3 avec appariement d'histogrammes	0,522 [0,478 ; 0,567] 55e	22,5 [20,9 ; 24,1] 52e	173 [131 ; 221] 54e	0,200 [0,171 ; 0,230] 58e	0,249 [0,224 ; 0,276] 56e	56e score 0,570
M3 sans normalisation	0,203 [0,172 ; 0,233] 58e	27,8 [25,9 ; 29,8] 55e	1 213 [776 ; 1 755] 58e	0,298 [0,278 ; 0,319] 56e	0,170 [0,142 ; 0,202] 57e	58e score 0,863

TABLE C.8 – Moyenne des cinq métriques par scanner sur les 110 cas de test et intervalle de confiance à 95 % (bootstrap stratifiés par scanner). Les deux dernières colonnes sont les scanners absents de l'entraînement.

Méthode	Métrique	Utrecht (30)	Singapour (30)	Ams. GE 3T (30)	Ams. Philips 3T (10)	Ams. GE 1,5T (10)
Augmentation forte (DA5)						
M1 avec augmentation forte (DA5)	Dice	0,761 [0,719 ; 0,801]	0,835 [0,806 ; 0,861]	0,802 [0,765 ; 0,834]	0,775 [0,695 ; 0,839]	0,806 [0,751 ; 0,854]
	HD95 (mm)	7,3 [5,0 ; 9,9]	4,6 [2,6 ; 7,7]	4,6 [2,9 ; 7,2]	9,4 [2,6 ; 19,4]	9,8 [2,1 ; 20,7]
	AVD (%)	25 [20 ; 31]	12 [9 ; 16]	14 [10 ; 20]	18 [9 ; 31]	5 [3 ; 7]
	Rappel lésionnel	0,643 [0,606 ; 0,677]	0,738 [0,703 ; 0,772]	0,774 [0,731 ; 0,811]	0,680 [0,597 ; 0,759]	0,849 [0,813 ; 0,883]
	F1 lésionnel	0,723 [0,681 ; 0,761]	0,794 [0,764 ; 0,821]	0,820 [0,790 ; 0,843]	0,787 [0,730 ; 0,840]	0,848 [0,816 ; 0,874]
Prétraitement des organisateurs						
M1 sur le prétraitement des organisateurs	Dice	0,787 [0,749 ; 0,821]	0,834 [0,802 ; 0,861]	0,796 [0,750 ; 0,833]	0,776 [0,703 ; 0,836]	0,808 [0,747 ; 0,856]
	HD95 (mm)	7,9 [5,6 ; 10,9]	4,5 [2,5 ; 7,5]	5,3 [3,3 ; 7,9]	9,7 [2,8 ; 20,9]	8,3 [2,3 ; 16,6]
	AVD (%)	21 [14 ; 29]	14 [10 ; 19]	16 [11 ; 21]	17 [9 ; 29]	7 [4 ; 10]
	Rappel lésionnel	0,643 [0,600 ; 0,677]	0,750 [0,719 ; 0,781]	0,765 [0,718 ; 0,808]	0,679 [0,595 ; 0,761]	0,807 [0,751 ; 0,859]
	F1 lésionnel	0,704 [0,662 ; 0,742]	0,802 [0,778 ; 0,824]	0,819 [0,788 ; 0,845]	0,781 [0,719 ; 0,836]	0,825 [0,768 ; 0,870]
Normalisation du seuillage						
M3 avec WhiteStripe	Dice	0,570 [0,485 ; 0,653]	0,618 [0,557 ; 0,678]	0,634 [0,580 ; 0,689]	0,613 [0,496 ; 0,711]	0,643 [0,533 ; 0,741]
	HD95 (mm)	23,4 [20,4 ; 26,4]	21,4 [18,3 ; 24,4]	23,6 [20,4 ; 27,1]	21,7 [19,6 ; 23,8]	21,9 [13,7 ; 31,9]
	AVD (%)	128 [68 ; 199]	41 [29 ; 56]	36 [26 ; 48]	45 [18 ; 83]	24 [13 ; 35]
	Rappel lésionnel	0,260 [0,231 ; 0,291]	0,140 [0,113 ; 0,170]	0,274 [0,231 ; 0,323]	0,209 [0,141 ; 0,292]	0,215 [0,176 ; 0,246]
	F1 lésionnel	0,302 [0,279 ; 0,326]	0,203 [0,174 ; 0,232]	0,341 [0,302 ; 0,377]	0,269 [0,203 ; 0,343]	0,331 [0,283 ; 0,374]
M3 avec appariement d'histogrammes	Dice	0,510 [0,424 ; 0,595]	0,585 [0,495 ; 0,666]	0,499 [0,418 ; 0,582]	0,472 [0,321 ; 0,615]	0,486 [0,319 ; 0,635]
	HD95 (mm)	23,0 [19,8 ; 26,3]	20,2 [17,7 ; 22,7]	24,3 [20,6 ; 27,9]	21,4 [18,3 ; 24,5]	24,1 [17,2 ; 31,5]
	AVD (%)	181 [93 ; 293]	133 [66 ; 210]	204 [127 ; 294]	219 [71 ; 414]	132 [44 ; 242]
	Rappel lésionnel	0,153 [0,111 ; 0,202]	0,152 [0,116 ; 0,192]	0,300 [0,225 ; 0,371]	0,218 [0,098 ; 0,383]	0,171 [0,096 ; 0,253]
	F1 lésionnel	0,214 [0,171 ; 0,261]	0,208 [0,170 ; 0,244]	0,327 [0,270 ; 0,389]	0,248 [0,152 ; 0,364]	0,245 [0,157 ; 0,343]
M3 sans normalisation	Dice	0,502 [0,423 ; 0,581]	0,001 [0,000 ; 0,003]	0,125 [0,080 ; 0,181]	0,000 [0,000 ; 0,000]	0,346 [0,179 ; 0,503]
	HD95 (mm)	24,3 [20,6 ; 28,0]	66,5 [66,5 ; 66,5]	31,1 [29,8 ; 32,4]	—†	23,0 [15,4 ; 31,7]
	AVD (%)	49 [37 ; 62]	100 [100 ; 100]	4 243 [2 662 ; 6 450]	100 [100 ; 100]	66 [47 ; 85]
	Rappel lésionnel	0,232 [0,186 ; 0,285]	0,001 [0,000 ; 0,002]	0,801 [0,754 ; 0,849]	0,000 [0,000 ; 0,000]	0,177 [0,075 ; 0,294]
	F1 lésionnel	0,260 [0,231 ; 0,290]	0,001 [0,000 ; 0,003]	0,286 [0,189 ; 0,394]	0,000 [0,000 ; 0,000]	0,225 [0,118 ; 0,338]

Le HD95 n'est défini que pour les patients où au moins un voxel est segmenté. † Le seuillage sans normalisation ne segmente rien chez les 10 patients d'Amsterdam Philips 3T.

Augmentation forte. La comparaison de M1 et de M1 entraîné avec DA5 forme une famille de cinq tests, une par métrique (tableau C.9).

TABLE C.9 – Augmentation forte (DA5) : comparaison appariée avec M1 sur les 110 cas de test. Différence moyenne avec intervalle de confiance à 95 % (bootstrap stratifié par scanner) et test de Wilcoxon signé, avant et après correction de Holm sur les 5 tests de cette famille. Une différence positive favorise M1 pour le Dice, le rappel et le F1, et la variante pour le HD95 et l'AVD.

Métrique	M1 − M1 DA5 [IC 95 %]	p	p corrigé
Dice	+0,005 [0,001 ; 0,009]	0,12	0,59
HD95 (mm)	−0,13 [−0,57 ; 0,23]	0,40	1
AVD (%)	−0,9 [−2,5 ; 0,7]	0,61	1
Rappel lésionnel	+0,002 [−0,007 ; 0,010]	0,39	1
F1 lésionnel	−0,003 [−0,011 ; 0,005]	0,75	1

Aucune différence n'est significative avant et après correction.

Prétraitement des organisateurs. La comparaison de M1 appliqué à nos images et aux images prétraitées par les organisateurs forme une famille de cinq tests, une par métrique (tableau C.10).

TABLE C.10 – Prétraitement des organisateurs : comparaison appariée avec M1 sur les 110 cas de test. Différence moyenne avce intervalle de confiance à 95 % (bootstrap stratifié par scanner) et test de Wilcoxon signé, avant et après correction de Holm sur les 5 tests de cette famille. Une différence positive favorise M1 pour le Dice, le rappel et le F1, et la variante pour le HD95 et l'AVD.

Métrique	M1 − M1 prétraitement des organisateurs [IC 95 %]	p	p corrigé
Dice	−0,001 [−0,006 ; 0,003]	0,91	1
HD95 (mm)	−0,32 [−0,65 ; −0,05]	0,07	0,35
AVD (%)	−0,7 [−2,2 ; 0,8]	0,93	1
Rappel lésionnel	+0,005 [−0,002 ; 0,013]	0,72	1
F1 lésionnel	+0,003 [−0,003 ; 0,009]	0,86	1

Aucune différence n'est significative après correction.

Généralisation de DA5. Cette question porte sur le gain de DA5 c'est-à-dire la différence entre DA5 et M1 calculée patient par patient et se demande s'il est plus grand sur les scanners inconnus que sur les scanners vus. Elle est posée sur les cinq métriques d'où une famille de 5 tests (tableau C.11).

TABLE C.11 – Généralisation de DA5 : gain de DA5 sur M1 (différence DA5 − M1 patient par patient) sur les scanners vus (90 patients) et inconnus (20 patients), écart entre les deux avec son intervalle de confiance à 95 % (bootstrap stratifié par scanner) et test de Mann-Whitney avant et après correction de Holm sur les 5 tests de cette famille.

Méthode	Métrique	Vus (90)	Inconnus (20)	Inconnus − vus [IC 95 %]	p	p corrigé
Gain DA5 − M1	Dice	−0,0058	+0,0002	+0,0059 [−0,0021 ; 0,0145]	0,36	0,73
	HD95 (mm)	−0,087	+1,123	+1,210 [−0,152 ; 3,087]	0,91	0,91
	AVD (%)	+1,72	−2,84	−4,56 [−9,63 ; 0,54]	0,053	0,27
	Rappel lésionnel	−0,0047	+0,0112	+0,0159 [−0,0008 ; 0,0339]	0,11	0,32
	F1 lésionnel	−0,0003	+0,0158	+0,0161 [−0,0008 ; 0,0321]	0,062	0,27

Aucun des 5 tests n'est significatif après correction (plus petit p corrigé de 0,27 pour l'AVD et le F1 lésionnel).

Normalisation : comparaison. Quelle normalisation choisir pour le seuillage ? Les quatre normalisations sont comparées deux à deux sur les cinq métriques, donc une famille de 30 tests (six paires, cinq métriques) tableau C.12.

TABLE C.12 – Comparaisons appariées des quatre normalisations du seuillage sur les 110 cas de test. Différence moyenne A − B avec intervalle de confiance à 95 % (bootstrap stratifié par scanner) et en dessous le p du test de Wilcoxon signé après correction de Holm sur les 30 tests de la famille. Un signe positif favorise A pour le Dice, le rappel et le F1, et B pour le HD95 et l'AVD.

Métrique	Z − W	Z − H	Z − A	W − H	W − A	H − A
Dice	−0,016 [−0,024 ; −0,010] $p = 5 \times 10^{-4}$	+0,073 [0,053 ; 0,095] $p = 4 \times 10^{-8}$	+0,392 [0,355 ; 0,429] $p = 2 \times 10^{-15}$	+0,090 [0,072 ; 0,108] $p = 3 \times 10^{-11}$	+0,409 [0,372 ; 0,446] $p = 1 \times 10^{-15}$	+0,319 [0,276 ; 0,367] $p = 7 \times 10^{-12}$
HD95 (mm)	+0,1 [−0,3 ; 0,4] $p = 1$	+0,2 [−0,9 ; 1,2] $p = 1$	−4,7 [−6,4 ; −3,1] $p = 8 \times 10^{-4}$	+0,1 [−0,9 ; 1,1] $p = 1$	−4,7 [−6,2 ; −3,1] $p = 8 \times 10^{-4}$	−4,4 [−6,2 ; −2,6] $p = 0{,}0062$
AVD (%)	+10 [5 ; 16] $p = 8 \times 10^{-4}$	−100 [−135 ; −67] $p = 2 \times 10^{-7}$	−1 140 [−1 684 ; −693] $p = 1 \times 10^{-8}$	−111 [−148 ; −78] $p = 7 \times 10^{-10}$	−1 150 [−1 682 ; −722] $p = 5 \times 10^{-9}$	−1 040 [−1 591 ; −598] $p = 0{,}012$
Rappel lésionnel	+0,006 [−0,000 ; 0,014] $p = 1$	+0,029 [0,010 ; 0,045] $p = 0{,}0073$	−0,069 [−0,093 ; −0,045] $p = 1$	+0,022 [0,003 ; 0,041] $p = 0{,}083$	−0,076 [−0,099 ; −0,053] $p = 1$	−0,098 [−0,128 ; −0,068] $p = 0{,}19$
F1 lésionnel	−0,001 [−0,008 ; 0,005] $p = 1$	+0,035 [0,014 ; 0,054] $p = 0{,}012$	+0,114 [0,081 ; 0,146] $p = 7 \times 10^{-9}$	+0,036 [0,014 ; 0,055] $p = 0{,}012$	+0,115 [0,079 ; 0,149] $p = 1 \times 10^{-8}$	+0,080 [0,039 ; 0,117] $p = 0{,}0013$

Z : z-score robuste (M3) ; W : WhiteStripe ; H : appariement d'histogrammes ; A : aucune normalisation.

Les trois normalisations par image font toutes mieux que l'absence de normalisation au Dice (de +0,32 à +0,41) et WhiteStripe fait mieux que le z-score (+0,016, $p = 5 \times 10^{-4}$ après correction).

Normalisation : effet du scanner. Le seuillage dépend-il du scanner selon la normalisation ? Le test de Kruskal-Wallis est appliqué à WhiteStripe, à l'appariement d'histogrammes et à l'absence de normalisation, soit une famille de 15 tests (trois normalisations, cinq métriques). eL z-score relève de l'étude centrale (tableau C.6). tableau C.13).

TABLE C.13 – Normalisation, effet du scanner : test de Kruskal-Wallis entre les cinq scanners. En haut le p brut et en dessous le p après correction de Holm sur les 15 tests de ces trois normalisations (le z-score, méthode M3, est au tableau C.6).

Méthode	Dice	HD95	AVD	Rappel	F1
M3 avec WhiteStripe	0,93 1	0,65 1	0,55 1	6×10^{-6} 7×10^{-5}	7×10^{-6} 7×10^{-5}
M3 avec appariement d'histogrammes	0,51 1	0,57 1	0,53 1	0,03 0,23	0,028 0,23
M3 sans normalisation	1×10^{-17} 2×10^{-16}	0,0047 0,042	1×10^{-18} 1×10^{-17}	3×10^{-20} 5×10^{-19}	2×10^{-15} 3×10^{-14}

Sans normalisation, les cinq métriques dépendent du scanner. Avec WhiteStripe seuls le rappel et le F1 lésionnels en dépendent, comme pour les méthodes de l'étude centrale. Avec l'appariement d'histogrammes, aucune métrique n'en dépend après correction.

C.4 Plafond inter-observateurs

Le plafond humain forme une catégorie à part car il ne compare pas des méthodes entre elles mais M1 aux experts. Sa famille compte 6 tests (deux experts, trois métriques symétriques).

TABLE C.14 – Accord entre experts sur les 60 cas d'entraînement, avec les métriques officielles. Pour O4 contre O3 l'AVD et le rappel dépendent de l'expert pris comme référence (ici O3) et ne sont donnés qu'à titre indicatif.

Comparaison (60 cas)	Dice	HD95 (mm)	AVD (%)	Rappel	F1
O3 contre O1	0,770	6,8	17	0,652	0,732
O4 contre O1	0,785	7,2	19	0,665	0,756
O4 contre O3	0,759	8,2	23	0,751	0,739

TABLE C.15 – M1 contre chaque expert sur les 12 cas de validation de M1 jugés contre O1. Dans chaque case on a la différence moyenne M1 − expert avec intervalle de confiance à 95 % (bootstrap stratifié par scanner) et le p du test de Wilcoxon signé avant et après correction de Holm sur les 6 tests de la famille ainsi que le nombre de patients où M1 est le plus proche de O1. Une différence positive favorise M1 pour le Dice et le F1, une différence négative pour le HD95.

Métrique	M1 − O3	M1 − O4
Dice	+0,058 [0,015 ; 0,108] $p = 0{,}027$; corrigé 0,16 M1 meilleur : 10 / 12	+0,034 [0,008 ; 0,063] $p = 0{,}052$; corrigé 0,26 M1 meilleur : 9 / 12
HD95 (mm)	−1,33 [−3,26 ; 0,27] $p = 0{,}34$; corrigé 1 M1 meilleur : 7 / 12	−0,62 [−1,74 ; 0,44] $p = 0{,}91$; corrigé 1 M1 meilleur : 5 / 12
F1 lésionnel	+0,041 [0,002 ; 0,083] $p = 0{,}15$; corrigé 0,61 M1 meilleur : 8 / 12	+0,002 [−0,022 ; 0,026] $p = 0{,}79$; corrigé 1 M1 meilleur : 7 / 12

D Biomarqueurs : définitions et résultats détaillés

Bland-Altman sur l'échelle logarithmique. Pour un patient i on note $d_i = \ln(s_i/r_i)$ la différence des logarithmes du biomarqueur de la source s et de la référence r (O1). Le biais est $\exp(\bar{d})$ (i.e.la moyenne géométrique des rapports). Les limites d'accord sont les exponentielles des 2,5^{e} et 97,5^{e} centiles des d_i. Un patient sans lésion profonde (ou périventriculaire) dans l'une des deux segmentations est exclu de ce biomarqueur, faute de logarithme.

ICC d'accord absolu. Sur le tableau $n \times k$ des logarithmes (n patients, $k = 2$ sources), l'analyse de variance à deux facteurs donne les carrés moyens des patients (MS_R), des sources (MS_C) et résiduel (MS_E), et

$$\mathrm{ICC}(A,1) = \frac{MS_R - MS_E}{MS_R + (k-1)\,MS_E + \frac{k}{n}\,(MS_C - MS_E)}.$$

Le terme en MS_C pénalise un écart systématique entre les deux sources, ce que ne fait pas l'ICC de cohérence. Son intervalle de confiance est obtenu par bootstrap stratifié par scanner.

Biais par site. Pour chaque source, biomarqueur et scanner, le biais reçoit un intervalle de confiance par bootstrap et un test de Wilcoxon contre zéro (le biais de ce scanner est-il non nul ?), corrigé par Holm sur l'ensemble de ces tests (84). Pour chaque source et biomarqueur un test de Kruskal-Wallis compare les d_i des scanners (le biais dépend-il du site ?) corrigé par Holm sur l'ensemble de ces tests (20). M1 sur les 12 cas de validation représente un échantillon trop peu nombreux pour des tests par site (quatre patients par scanner) et est comparé aux experts à part (tableau D.4).

Cartes de fréquence lésionnelle. Chaque masque est transporté de la grille de la FLAIR à celle de la T1 brute (inverse du recalage rigide) puis vers le modèle MNI152NLin2009cAsym à 2 mm (transformation affine et déformation SyN) avec une interpolation linéaire qui conserve la fraction de chaque voxel couverte par une lésion. La carte d'un groupe est la moyenne de ces fractions sur ses patients et l'accord avec O1 est la corrélation de Pearson voxel à voxel dans le cerveau, sur les mêmes patients.

Table D.1 – Biomarqueurs de la référence O1 par scanner (médianes sur les 170 patients). Les scanners marqués d'un astérisque sont absents de l'entraînement.

Scanner	Patients	Volume (ml)	% de l'ICV	Part périventriculaire	Lésions ≥ 10 mm^3	ICV (ml)
Utrecht	50	13,9	0,92	0,80	47,5	1517
Singapour	50	15,9	1,18	0,85	31,5	1347
Ams. GE 3T	50	6,3	0,44	0,87	36,5	1465
Ams. Philips 3T*	10	7,6	0,57	0,84	54,0	1445
Ams. GE 1,5T*	10	8,5	0,67	0,87	33,0	1485
Tous	170	11,2	0,74	0,83	37,0	1450

TABLE D.2 – Accord des quatre biomarqueurs avec O1 : biais, limites d'accord, ICC d'accord absolu et intervalle de confiance (bootstrap), p du test de Kruskal-Wallis de l'effet du site corrigé par Holm. La fraction du volume intracrânien est issue du volume total donc exclu de cette analyse

Source	Patients	Biais	Limites d'accord	ICC [IC 95 %]	Biais dépendant du site (p)
Volume total					
M1 nnU-Net (test, 110)	110	0,98	[0,54 ; 1,31]	0,982 [0,975 ; 0,988]	0,0034
M2 WMH-SynthSeg (test, 110)	110	2,44	[0,70 ; 16,3]	0,372 [0,278 ; 0,468]	0,44
M3 seuillage (test, 110)	110	1,18	[0,38 ; 6,14]	0,814 [0,733 ; 0,873]	0,0035
Expert O3 (entraînement, 60)	60	0,97	[0,61 ; 1,47]	0,981 [0,968 ; 0,990]	0,0036
Expert O4 (entraînement, 60)	60	0,91	[0,57 ; 1,61]	0,977 [0,965 ; 0,987]	0,0027
Volume périventriculaire					
M1 nnU-Net (test, 110)	110	1,00	[0,54 ; 1,32]	0,982 [0,974 ; 0,988]	0,013
M2 WMH-SynthSeg (test, 110)	110	2,53	[0,77 ; 14,3]	0,349 [0,261 ; 0,440]	0,44
M3 seuillage (test, 110)	110	1,21	[0,45 ; 4,58]	0,852 [0,794 ; 0,897]	0,0034
Expert O3 (entraînement, 60)	60	0,98	[0,61 ; 1,49]	0,980 [0,968 ; 0,988]	0,0041
Expert O4 (entraînement, 60)	60	0,94	[0,55 ; 1,91]	0,975 [0,963 ; 0,985]	0,0034
Volume profond					
M1 nnU-Net (test, 110)	108	0,87	[0,31 ; 1,40]	0,964 [0,933 ; 0,984]	0,0013
M2 WMH-SynthSeg (test, 110)	109	2,23	[0,34 ; 61,7]	0,436 [0,292 ; 0,579]	0,62
M3 seuillage (test, 110)	107	0,93	[0,11 ; 37,1]	0,543 [0,398 ; 0,664]	0,0029
Expert O3 (entraînement, 60)	59	0,86	[0,31 ; 1,45]	0,969 [0,944 ; 0,985]	0,013
Expert O4 (entraînement, 60)	60	0,78	[0,36 ; 1,08]	0,968 [0,947 ; 0,983]	0,0041
Nombre de lésions $\geq$ 10 mm^3					
M1 nnU-Net (test, 110)	110	0,82	[0,58 ; 1,16]	0,890 [0,853 ; 0,917]	6×10^{-4}
M2 WMH-SynthSeg (test, 110)	110	0,44	[0,23 ; 1,12]	0,300 [0,232 ; 0,363]	0,62
M3 seuillage (test, 110)	110	0,55	[0,25 ; 1,67]	0,305 [0,205 ; 0,390]	0,44
Expert O3 (entraînement, 60)	60	0,79	[0,48 ; 1,15]	0,847 [0,770 ; 0,899]	0,0057
Expert O4 (entraînement, 60)	60	0,80	[0,51 ; 1,15]	0,877 [0,817 ; 0,921]	0,62

TABLE D.3 – Biais par scanner des quatre biomarqueurs : rapport moyen à O1, intervalle de confiance à 95 % (bootstrap) et p du test de Wilcoxon contre zéro, avant et (entre parenthèses) après correction de Holm sur les 84 tests du tableau. Les experts n'ont délimité que les trois scanners d'entraînement. Les scanners marqués d'un astérisque sont absents de l'entraînement.

Scanner	M1 nnU-Net	M2 WMH-SynthSeg	M3 seuillage	Expert O3	Expert O4
Volume total					
Utrecht	0,87 [0,80 ; 0,95] $p = 1 \times 10^{-3}$ (0,053)	2,24 [1,58 ; 3,17] $p = 3 \times 10^{-5}$ (0,0023)	1,72 [1,31 ; 2,25] $p = 9 \times 10^{-5}$ (0,0057)	1,13 [1,04 ; 1,24] $p = 0{,}0032$ (0,15)	0,96 [0,83 ; 1,10] $p = 0{,}083$ (1)
Singapour	1,03 [0,97 ; 1,10] $p = 0{,}10$ (1)	1,85 [1,43 ; 2,47] $p = 3 \times 10^{-5}$ (0,0018)	0,79 [0,64 ; 0,99] $p = 0{,}029$ (1)	0,90 [0,83 ; 0,97] $p = 0{,}0073$ (0,28)	0,80 [0,75 ; 0,85] $p = 3 \times 10^{-5}$ (0,0018)
Ams. GE 3T	1,01 [0,92 ; 1,09] $p = 0{,}045$ (1)	3,32 [2,49 ; 4,46] $p = 2 \times 10^{-9}$ (2×10^{-7})	1,28 [1,10 ; 1,49] $p = 0{,}0066$ (0,27)	0,89 [0,79 ; 0,99] $p = 0{,}07$ (1)	1,00 [0,90 ; 1,08] $p = 0{,}78$ (1)
Ams. Philips 3T*	0,98 [0,81 ; 1,13] $p = 0{,}49$ (1)	2,42 [1,59 ; 4,08] $p = 0{,}002$ (0,11)	1,16 [0,91 ; 1,55] $p = 0{,}49$ (1)	—	—
Ams. GE 1,5T*	1,10 [1,06 ; 1,14] $p = 0{,}0039$ (0,18)	2,84 [1,56 ; 5,74] $p = 0{,}0059$ (0,25)	0,96 [0,77 ; 1,22] $p = 0{,}92$ (1)	—	—
Volume périventriculaire					
Utrecht	0,90 [0,83 ; 0,99] $p = 0{,}011$ (0,41)	2,39 [1,71 ; 3,35] $p = 7 \times 10^{-6}$ (5×10^{-4})	1,67 [1,34 ; 2,11] $p = 7 \times 10^{-6}$ (5×10^{-4})	1,16 [1,06 ; 1,27] $p = 0{,}0023$ (0,11)	0,98 [0,85 ; 1,13] $p = 0{,}13$ (1)
Singapour	1,05 [0,98 ; 1,12] $p = 0{,}045$ (1)	1,92 [1,49 ; 2,55] $p = 6 \times 10^{-6}$ (4×10^{-4})	0,85 [0,71 ; 1,01] $p = 0{,}096$ (1)	0,92 [0,86 ; 0,99] $p = 0{,}058$ (1)	0,83 [0,77 ; 0,92] $p = 9 \times 10^{-4}$ (0,048)
Ams. GE 3T	1,02 [0,93 ; 1,10] $p = 0{,}04$ (1)	3,30 [2,49 ; 4,38] $p = 2 \times 10^{-9}$ (2×10^{-7})	1,32 [1,17 ; 1,48] $p = 2 \times 10^{-4}$ (0,013)	0,89 [0,78 ; 0,99] $p = 0{,}076$ (1)	1,01 [0,91 ; 1,10] $p = 0{,}70$ (1)
Ams. Philips 3T*	0,98 [0,82 ; 1,14] $p = 0{,}49$ (1)	2,51 [1,67 ; 4,19] $p = 0{,}002$ (0,11)	1,21 [0,99 ; 1,49] $p = 0{,}19$ (1)	—	—
Ams. GE 1,5T*	1,11 [1,06 ; 1,17] $p = 0{,}0059$ (0,25)	3,17 [1,75 ; 6,12] $p = 0{,}002$ (0,11)	1,03 [0,82 ; 1,28] $p = 1$ (1)	—	—
Volume profond					
Utrecht	0,72 [0,64 ; 0,80] $p = 7 \times 10^{-7}$ (6×10^{-5})	1,80 [1,18 ; 2,76] $p = 0{,}0071$ (0,28)	1,91 [1,24 ; 3,04] $p = 0{,}052$ (1)	0,99 [0,85 ; 1,16] $p = 0{,}77$ (1)	0,75 [0,60 ; 0,88] $p = 2 \times 10^{-4}$ (0,013)
Singapour	0,96 [0,88 ; 1,04] $p = 0{,}39$ (1)	1,63 [1,13 ; 2,49] $p = 0{,}07$ (1)	0,44 [0,27 ; 0,78] $p = 0{,}004$ (0,18)	0,73 [0,62 ; 0,83] $p = 2 \times 10^{-5}$ (0,0013)	0,67 [0,62 ; 0,73] $p = 4 \times 10^{-6}$ (3×10^{-4})
Ams. GE 3T	0,92 [0,70 ; 1,11] $p = 0{,}44$ (1)	4,18 [2,38 ; 8,05] $p = 1 \times 10^{-5}$ (1×10^{-3})	1,10 [0,67 ; 1,93] $p = 0{,}88$ (1)	0,88 [0,76 ; 0,99] $p = 0{,}033$ (1)	0,94 [0,83 ; 1,07] $p = 0{,}14$ (1)
Ams. Philips 3T*	0,87 [0,62 ; 1,14] $p = 1$ (1)	1,96 [0,92 ; 4,67] $p = 0{,}16$ (1)	0,94 [0,49 ; 1,91] $p = 1$ (1)	—	—
Ams. GE 1,5T*	0,95 [0,83 ; 1,07] $p = 0{,}91$ (1)	2,00 [0,94 ; 4,56] $p = 0{,}13$ (1)	0,59 [0,40 ; 0,90] $p = 0{,}074$ (1)	—	—
Nombre de lésions ≥ 10 mm³ (rapport de $x+1$)					
Utrecht	0,75 [0,70 ; 0,81] $p = 1 \times 10^{-5}$ (9×10^{-4})	0,43 [0,37 ; 0,51] $p = 1 \times 10^{-8}$ (1×10^{-6})	0,70 [0,57 ; 0,86] $p = 0{,}0034$ (0,16)	0,75 [0,70 ; 0,81] $p = 1 \times 10^{-4}$ (0,0074)	0,75 [0,69 ; 0,81] $p = 9 \times 10^{-5}$ (0,0057)
Singapour	0,82 [0,78 ; 0,86] $p = 6 \times 10^{-6}$ (4×10^{-4})	0,46 [0,42 ; 0,51] $p = 2 \times 10^{-6}$ (1×10^{-4})	0,48 [0,40 ; 0,58] $p = 2 \times 10^{-5}$ (0,0011)	0,73 [0,66 ; 0,81] $p = 5 \times 10^{-5}$ (0,0031)	0,81 [0,75 ; 0,87] $p = 2 \times 10^{-4}$ (0,014)
Ams. GE 3T	0,89 [0,85 ; 0,94] $p = 8 \times 10^{-4}$ (0,045)	0,42 [0,36 ; 0,50] $p = 3 \times 10^{-6}$ (2×10^{-4})	0,55 [0,46 ; 0,65] $p = 1 \times 10^{-6}$ (1×10^{-4})	0,89 [0,81 ; 0,96] $p = 0{,}015$ (0,52)	0,84 [0,76 ; 0,92] $p = 0{,}0037$ (0,17)
Ams. Philips 3T*	0,73 [0,61 ; 0,82] $p = 0{,}002$ (0,11)	0,44 [0,36 ; 0,55] $p = 0{,}002$ (0,11)	0,53 [0,40 ; 0,73] $p = 0{,}0098$ (0,36)	—	—
Ams. GE 1,5T*	0,99 [0,91 ; 1,10] $p = 0{,}82$ (1)	0,42 [0,32 ; 0,54] $p = 0{,}002$ (0,11)	0,45 [0,37 ; 0,56] $p = 0{,}0039$ (0,18)	—	—

TABLE D.4 – Plafond humain des biomarqueurs : M1 et les experts O3 et O4 contre O1 sur les 12 cas de validation de M1 (les seuls que M1 n'a pas vu pendant l'entrainement). Biais, étendue des rapports par patient (le plus faible et le plus fort car sur 12 patients les centiles 2,5 et 97,5 n'auraient pas de sens) et ICC d'accord absolu [IC 95 %, bootstrap stratifié par scanner]. Pas de test par site avec quatre patients par scanner.

Source	Biais	Étendue des rapports	ICC [IC 95 %]
Volume total			
M1 nnU-Net	0,87	[0,69 ; 1,05]	0,990 [0,968 ; 0,995]
Expert O3	0,93	[0,41 ; 1,50]	0,976 [0,904 ; 0,998]
Expert O4	0,95	[0,64 ; 1,77]	0,976 [0,939 ; 0,988]
Volume périventriculaire			
M1 nnU-Net	0,90	[0,73 ; 1,10]	0,992 [0,972 ; 0,996]
Expert O3	0,96	[0,44 ; 1,49]	0,977 [0,911 ; 0,998]
Expert O4	0,97	[0,62 ; 2,00]	0,969 [0,918 ; 0,988]
Volume profond			
M1 nnU-Net	0,70	[0,30 ; 1,02]	0,971 [0,925 ; 0,991]
Expert O3	0,84	[0,27 ; 1,56]	0,971 [0,883 ; 0,994]
Expert O4	0,76	[0,19 ; 2,47]	0,949 [0,893 ; 0,984]
Nombre de lésions $\geq$ *10 mm*^{3}			
M1 nnU-Net	0,80	[0,61 ; 1,00]	0,938 [0,854 ; 0,972]
Expert O3	0,83	[0,54 ; 1,14]	0,934 [0,836 ; 0,975]
Expert O4	0,87	[0,75 ; 1,36]	0,966 [0,923 ; 0,981]

TABLE D.5 – Corrélation de Pearson voxel à voxel entre la carte de fréquence lésionnelle de chaque source et celle de O1 (sur les 110 cas de test pour les méthodes et les 60 cas d'entraînement pour les experts). Une carte faite sur moins de patients est plus bruitée ce qui baisse mécaniquement la corrélation donc la comparaison avec les experts est indicative seulement.

Site	M1 nnU-Net	M2 WMH-SynthSeg	M3 seuillage	Expert O3	Expert O4
Tous	0,995	0,879	0,903	0,993	0,992
Utrecht	0,979	0,859	0,855	0,985	0,987
Singapour	0,992	0,881	0,886	0,986	0,977
Ams. GE 3T	0,987	0,816	0,887	0,972	0,979
Ams. Philips 3T*	0,969	0,796	0,848	—	—
Ams. GE 1,5T*	0,970	0,668	0,887	—	—

E Harmonisation : définitions et résultats détaillés

Caractéristiques. Pour chaque patient et chaque modalité (FLAIR et T1 corrigées par N4, la T1 sur la grille de la FLAIR) la substance blanche d'apparence saine (SBS) est prise comme l'union des étiquettes de substance blanche de WMH-SynthSeg (2 et 41), qui exclut les HSB (étiquette 77). Le cortex est pris comme l'union des étiquettes 3 et 42, toutes deux dans le masque du cerveau HD-BET. On en tire dix caractéristiques par modalité : les 5e, 25e, 50e, 75e et 95e centiles de la SBS, son écart interquartile, son asymétrie et son aplatissement, la médiane du cortex et l'écart entre la médiane du cortex et celle de la SBS. On réalise une exprience sans normalisation (l'image est divisée par la médiane des cerveaux d'entraînement) et avec le z-score robuste (par la médiane et l'écart absolu médian du cerveau de chaque image).

Classifieur de site. Les 20 caractéristiques sont centrées et réduites puis une régression logistique multinomiale prédit le scanner. La validation croisée compte 5 plis stratifiés par scanner (graine fixée) et la performance est la précision équilibrée (moyenne des taux de bonne classification de chaque scanner), qui vaut 20 % au hasard quels que soient les effectifs des scanners.

ComBat. Pour la caractéristique g du patient j du site i, ComBat suppose

$$y_{ijg} = \alpha_g + X_{ij}\,\beta_g + \gamma_{ig} + \delta_{ig}\,\varepsilon_{ijg},$$

où α_g est le niveau moyen, $X_{ij}\,\beta_g$ l'effet des covariables biologiques (ici ln(1+volume de HSB de O1) et le volume intracrânien), γ_{ig} le décalage additif du site, δ_{ig} son facteur d'échelle et ε_{ijg} le bruit. Les paramètres de site sont estimés par Bayes empirique, en supposant que les γ_{ig} et δ_{ig} d'un même site suivent une loi commune à toutes ses caractéristiques. La valeur harmonisée retire les deux effets de site en gardant l'effet des covariables : $y^{*}_{ijg} = (y_{ijg} - \hat{\alpha}_g - X_{ij}\hat{\beta}_g - \hat{\gamma}_{ig})/\hat{\delta}_{ig} + \hat{\alpha}_g + X_{ij}\hat{\beta}_g$. Dans le classifieur, ComBat est appris sur les plis d'entraînement et appliqué au pli de test ; pour le contrôle de la biologie, il est appris sur les 170 patients.

Part de variance due au site. Pour une caractéristique, η^2 est le rapport de la somme des carrés entre scanners à la somme des carrés totale, dans une analyse de variance à un facteur (le scanner) : $\eta^2 = 0$ si toutes les moyennes de scanner sont égales, $\eta^2 = 1$ si toute la variabilité vient du scanner.

TABLE E.1 – Précision équilibrée du classifieur de site par échelle, avant et après ComBat : moyenne et écart type entre les 5 plis de la validation croisée (hasard : 20 %).

Échelle	Avant ComBat	Après ComBat
Sans normalisation	90 % ± 6 %	29 % ± 6 %
z-score robuste par image	73 % ± 8 %	28 % ± 4 %

TABLE E.2 – Les 20 caractéristiques de la substance blanche saine (SBS) : part de variance due au site (η^2) et corrélation de Spearman avec la charge lésionnelle (ρ), avant et après ComBat (appris sur les 170 patients), sans normalisation et après le z-score robuste par image.

		Sans normalisation				z-score robuste			
Modalité	Caractéristique	η^2 avant	η^2 après	ρ avant	ρ après	η^2 avant	η^2 après	ρ avant	ρ après
FLAIR	SBS, 5e centile	0,84	0,02	0,02	0,22	0,27	0,01	0,44	0,50
FLAIR	SBS, 25e centile	0,85	0,02	0,01	0,21	0,18	0,02	0,42	0,45
FLAIR	SBS, médiane	0,86	0,02	0,01	0,21	0,11	0,02	0,42	0,43
FLAIR	SBS, 75e centile	0,86	0,02	0,02	0,22	0,08	0,02	0,48	0,44
FLAIR	SBS, 95e centile	0,84	0,03	0,06	0,32	0,14	0,03	0,64	0,58
FLAIR	SBS, écart interquartile	0,77	0,01	0,02	0,16	0,29	0,00	−0,20	−0,27
FLAIR	SBS, asymétrie	0,10	0,03	0,58	0,64	0,10	0,02	0,58	0,64
FLAIR	SBS, aplatissement	0,05	0,02	0,46	0,42	0,05	0,02	0,46	0,44
FLAIR	cortex, médiane	0,89	0,02	−0,03	0,13	0,23	0,04	−0,57	−0,59
FLAIR	contraste cortex − SBS	0,56	0,01	−0,36	−0,36	0,13	0,03	−0,52	−0,51
T1	SBS, 5e centile	0,80	0,01	−0,34	−0,31	0,15	0,03	−0,39	−0,45
T1	SBS, 25e centile	0,82	0,01	−0,33	−0,28	0,16	0,02	−0,37	−0,41
T1	SBS, médiane	0,82	0,01	−0,32	−0,27	0,16	0,00	−0,10	−0,11
T1	SBS, 75e centile	0,83	0,01	−0,31	−0,26	0,26	0,01	0,18	0,27
T1	SBS, 95e centile	0,84	0,01	−0,31	−0,25	0,28	0,02	0,30	0,42
T1	SBS, écart interquartile	0,87	0,02	−0,08	0,01	0,23	0,03	0,40	0,51
T1	SBS, asymétrie	0,41	0,01	0,43	0,42	0,41	0,02	0,43	0,42
T1	SBS, aplatissement	0,64	0,02	−0,39	−0,38	0,64	0,03	−0,39	−0,39
T1	cortex, médiane	0,83	0,02	−0,29	−0,22	0,21	0,01	0,41	0,48
T1	contraste cortex − SBS	0,77	0,01	0,33	0,30	0,20	0,01	0,37	0,43

F Reproductibilité : environnement, workflow et paramètres

Environnement. Le tableau F.1 donne les versions des principales bibliothèques, telles que les fixe le fichier de verrouillage `uv.lock` (Python 3.12). Les étapes exécutées sur Kaggle (entraînements de nnU-Net, WMH-SynthSeg) tournent dans l'environnement de Kaggle avec les mêmes versions de nnU-Net installées par les carnets.

TABLE F.1 – Versions des principales bibliothèques (fichier `uv.lock`).

Bibliothèque	Version	Rôle
Imagerie		
nibabel	5.4.2	lecture et écriture NIfTI
simpleitk	2.5.6	script officiel du challenge
antspyx	0.6.3	N4, recalages rigide et SyN
templateflow	25.1.2	modèle MNI152NLin2009cAsym [35]
Apprentissage profond		
torch	2.14.1	PyTorch
nnunetv2	2.8.1	M1
hd-bet	2.0.1	masque du cerveau
torchio	1.2.1	artefacts simulés
Statistiques et harmonisation		
numpy	2.3.5	
scipy	1.15.3	tests statistiques
pandas	3.0.6	
statsmodels	0.15.0	MAD, statistiques des tissus
scikit-learn	1.9.1	forêt d'isolement, classifieur de site
neuroharmonize	2.4.5	ComBat
neurocombat	0.2.12	ComBat
Workflow et tests		
snakemake	9.27.0	workflow
pytest	9.1.1	tests automatiques

Workflow. Le tableau F.2 décrit les 25 règles du workflow Snakemake (`workflow/Snakefile`), où elles s'exécutent et la section du rapport qu'elles alimentent. Les deux étapes externes s'arrêtent en indiquant le carnet Kaggle à lancer si leurs sorties manquent.

TABLE F.2 – Règles du workflow Snakemake. GPU local : carte graphique de 8 Go ; Kaggle : 2 GPU T4.

Règle	Rôle	Exécution	Section
Données			
`download`	téléchargement depuis DataverseNL, empreintes SHA-1	local	2
`bids`	conversion BIDS et inventaire	local	3.1
Prétraitement			
`register`	recalage rigide T1 vers FLAIR, contrôle contre elastix	local	3.2
`brainmask`	masques HD-BET, transport sur la grille FLAIR	GPU local	3.3
`bias`	correction N4	local	3.3
`syn_mni`	recalage SyN vers le modèle MNI à 2 mm	local	3.4
Contrôle qualité			
`qc_iqm`	indicateurs de qualité	local	4.1
`qc_outliers`	z-scores par scanner, forêt d'isolement	local	4.2
`qc_artifacts`	détection des artefacts simulés	local	4.4
`robustness`	nnU-Net sur les FLAIR dégradées	GPU local	4.4
`qc_report`	rapport visuel (local, jamais publié)	local	4
Segmentation			
`nnunet_export`	jeu de données nnU-Net et plis	local	5.1
`kaggle_nnunet_training`	entraînement de M1 et de DA5 (étape externe)	Kaggle	5.1
`nnunet_infer`	inférence de M1 et de ses variantes	GPU local	5.1
`kaggle_wmhsynthseg`	WMH-SynthSeg (étape externe)	Kaggle	5.2
`threshold`	seuillage et ses normalisations	local	5.3, 5.4
Évaluation			
`evaluate`	métriques officielles par méthode	local	6.1
`stats`	intervalles, tests appariés, scanners, effet du scanner	local	6
`interobserver`	plafond inter-observateurs	local	6.6
`figures`	figures et position au classement	local	6.3
Biomarqueurs			
`biomarkers`	volumes, localisation, lésions	local	7.1
`agreement`	Bland-Altman, ICC, biais par site	local	7.2, 7.3
`mni_maps`	cartes de fréquence lésionnelle	local	7.4
Harmonisation			
`nawm_features`	caractéristiques de la substance blanche saine	local	8.1
`combat`	classifieur de site et ComBat	local	8.2, 8.3

Paramètres. Tous les paramètres sont réunis dans `config/config.yaml`, le tableau F.3 rassemble ceux qui déterminent les résultats de ce rapport.

TABLE F.3 – Principaux paramètres (fichier `config/config.yaml`).

Paramètre	Valeur	Section
Aléatoire		
graine (plis, bootstrap, forêt, artefacts, ComBat)	42	toutes
Contrôle qualité		
seuil « à vérifier » / « à exclure » (z robuste)	3 / 5	4.2
proportion attendue d'atypiques (forêt d'isolement)	0,05	4.2
images minimum par scanner pour un z-score	8	4.2
marge exclue autour des HSB	2 mm	4.1
patients de test par scanner (artefacts)	6	4.4
Segmentation		
nnU-Net : configuration, époques, pli	3d_fullres, 250, pli 0	5.1
seuillage : grille de t (z-score)	1,0 à 4,0, pas 0,1	5.3
seuillage : paramètres retenus (t, e, m)	2,2 ; 14 mm ; 40 mm^3	5.3
Évaluation		
tirages bootstrap ; niveau de confiance	2 000 ; 95 %	6.2
familles de tests (correction de Holm)	tableau 5	6
Biomarqueurs		
distance périventriculaire	10 mm	7.1
taille minimale d'une lésion comptée	10 mm^3	7.1
résolution des cartes MNI	2 mm	7.4